Đ 8

广州城市理工学院

校级大学生创新创业训练计划项目(SRP)
结题报告书

项目编号：J312514

项目名称：机器学习驱动的多指标时序动态综合指数构建及其在碳排放评估中的应用

起止时间：2025年4月至2026年3月

学生姓名：李铮、王瑾蔺、梁慧欣、江晓珊、陆烨

学院专业：管理学院、大数据管理与应用专业

联系电话：19806429363

电子信箱：2519153001@qq.com

指导教师：马琦，ZHIXUAN CHEN

广州城市理工学院教务处

二〇二六年三月

项目名称	机器学习驱动的多指标时序动态综合指数构建及其在碳排放评估中的应用
项目性质	☐发明、设计　☐基础性研究　☑应用性研究　☐社会调研
项目来源	☐自主立题　☐教师指导选题

指导教师	姓名	职位/职称	联系电话	Email
	马琦	副教授	15989191708	maqi@gcu.edu.cn
	ZHIXUAN CHEN	副教授	13544596060	Chenzx@gcu.edu.cn

一、项目成果简介：（重点介绍特色及创新点，200 字左右）

本项目构建了机器学习驱动的多指标时序动态综合指数框架，并应用于碳排放评估。项目特色在于多学科深度交叉，融合机器学习、统计学与领域知识，实现指数动态实时更新。创新点包括：首创机器学习驱动的动态权重分配机制，捕捉指标间非线性关系；提出深度学习与传统统计结合的混合建模框架，兼顾高性能与可解释性；建立基于在线学习的自适应更新机制。研究成果显著提升综合指数科学性与时效性，为复杂系统监测与决策支持提供新范式。

二、项目研究中使用的具体材料：（含参阅的书籍和论文目录，使用的检索目录）

[1] OECD. (2008). Handbook on Constructing Composite Indicators: Methodology and User Guide. OECD Publishing.

[2] Mazziotta, M., & Pareto, A. (2019). Synthesis of indicators: The non-aggregative approach. Social Indicators Research, 143(1), 381–396.

[3] Kuc-Czarnecka, M., Lo Piano, S., & Saltelli, A. (2020). Quantitative storytelling in the making of a composite indicator. Ecological Economics, 168, 106483.

[4] Cavicchia, C., & Vichi, M. (2021). Statistical model-based composite indicators for tracking coherent policy conclusions. Social Indicators Research, 156(2), 449-479.

[5] Mazziotta, M., Pareto, A. Principal component analysis for constructing socio-economic composite indicators: theoretical and empirical considerations. SN Soc Sci 4, 114 (2024). https://doi.org/10.1007/s43545-024-00920-x

[6] Greco, S., Ishizaka, A., Tasiou, M., & Torrisi, G. (2022). The use of composite indicators to evaluate the performance of Brazilian hydropower plants. European Journal of Operational Research, 299(1), 352–364.

[7] Zhang, L. P., & Zhou, P. (2024). Reassessing energy security risk incorporating external shock: a variance-based composite indicator approach. Applied energy, 358, 122665.

[8] D'Amico, S., & Vitale, C. (2023). A functional approach for constructing dynamic composite indicators. Statistical Methods & Applications, 32, 19–42.

[9] Borgonovo, E., et al. (2025). Sensitivity-based weighting method for composite indicators. Annals of Operations Research.

[10] Kelemen, A., SzabÃ³, Z. K., BozÃ³ki, S., SzÃ¡doczki, Z., & Hartvig, Ã□. D. (2024). A sensitivity analysis of composite indicators: Min/max thresholds. Environmental and Sustainability Indicators, 23, 100453.

[11] 邱东. (2018). 经济测度逻辑挖掘: 困难与原则. 北京: 科学出版社.

[12] 王筱明, 陈柏成, 周景红. (2020). 基于时序多指标动态评价的山东省城市土地利用效益比较研究. 湖南师范大学自然科学学报, 43(04), 1-8.

[13] 何赟, 等. (2025). 基于时间序列分析的中欧班列高质量发展动态评价体系构建. 交通运输系统工程与信息, 25(2), 45-56.

[14] 谢艾玉, 等. (2025). 基于变异系数动态赋权与混合隶属度函数的湖泊水质时空评价模型. 环境科学学报, 45(3), 1128-1139.

[15] 邱东, 刘颖, 平卫英. (2025). 从方法提升到方法论——注重多指标综合评价的机理进路. 统计研究, 42(04), 3-14.

三、项目成果形式及数量：（需另行提供附件、电子版和模型演示光盘等）

1. ☐文献资料综述（　　）份；2. ☐调查报告（　　）份；3. ☑研究论文（ 3 ）份；
4. ☐软件（　　）份；5. ☐设计（　　）份；6. ☐硬件研制（　　）份；
7. ☐获得专利（　　）份；8. ☐心得体会（　　）份；9. ☐实物模型（　　）份；
10. ☐其他（　　）件，名称：_____

附件清单：

1. JINLIN WANG, ZHIXUAN CHEN & QI MA. A Multi-Model Weighted Ensemble Approach for MET Prediction Using Wearable Accelerometer Data. BDIOT2025.

2. ZHIXUAN CHEN, QI MA & JINLIN WANG. Intelligent Decision Modeling in Smart Commerce: A Curvature Mass-Aware Classification Framework. ICEME2026. （审稿中）

3. ZHIXUAN CHEN, QI MA & JINLIN WANG. Construction of multi-Index Time series dynamic comprehensive Index driven by machine learning and its application in carbon emission assessment. 投稿准备中（目标期刊：国际期刊《Research Policy》, SSCI　JCR Q1）

四、项目总结报告（以学术论文形式撰写，应包含项目实施过程中创新思维和创新实践方面收获，3000～4000 字）：

第一章 引言

1.1 研究背景

多指标综合评价作为管理科学与系统工程领域的核心方法论，是将复杂系统中的多维异质信息集成为综合测度指数的关键工具，长期以来被广泛应用于经济绩效、社会发展及政策评估等多个维度的测度。在数字经济时代，管理决策的范式正从静态截面与面板评估向动态前瞻性评估演进。在经济系统内生演进与外部环境动态变化的双重驱动下，多维评价指标呈现出复杂的时序特征，其长期演变轨迹蕴含的结构性信息远超单一时间截面，这种时序深度不仅反映历史表现，更蕴含对未来决策具有关键价值的前瞻性信号。然而，当前主流的多指标综合评价方法如经典的熵权法 EWM、TOPSIS 等，其理论框架与计算逻辑主要基于截面数据的代数特征设计，天然缺乏对时间维度的内生处理机制。当这些静态方法被直接应用于时序评价场景时，面临着一个基础性的方法论挑战，传统方法基于独立同分布的隐含假设，忽视了时序数据中内嵌的路径依赖特征，无法有效剥离并区分结构性发展趋势与随机性短期波动，这种机理上的错配导致了评价结果的偏差。例如传统方法极易将由外部冲击引起的短期高频噪声误判为高信息量的变异信号，从而赋予其过高权重；反之，平稳演进的长期趋势信号则可能因变异程度低而被不当忽略。这种对短期扰动的过度敏感或对长期趋势的系统性忽视，不仅降低了权重的可解释性，更可能导致评价结果在时间轴上不稳定性，难以通过稳健性检验，进而误导管理者的战略判断。

现有动态综合评价研究已取得显著进展，例如基于相对熵距离构建的动态改进 TOPSIS 方法（Li et al., 2023）以及面向多源异构数据融合的改进熵权－TOPSIS 框架（Liu et al., 2022）。然而，这些方法仍主要侧重于评价体系的时序延展或静态指标的动态加权设计，较少从时间序列数据的生成机制的视角出发，对结构性趋势与随机扰动进行显式建模，难以在评价过程中实现对长期发展潜能的稳健识别。因此，如何构建一种融合时序预测与特征识别能力的综合评价框架，借助机器学习强大的非线性模式挖掘能力，自适应地识别和建模时序数据中蕴含的结构性趋势如线性/非线性趋势、季节性、周期转折点，以及随机性扰动如异常值、噪声的复杂关系，实现对评价对象动态演进的本质规律与扰动因素的有效区分，进而建立兼顾历史表现与未来潜力的动态权重分配框架，已成为突破当前方法局限的关键路径。基于此本研究提出基于时间注意力与融合机器学习挖掘能力的动态综合指数构建框架，以实现趋势-扰动解耦和时间自适应科学调节设计。

1.2 研究意义

本研究的意义深刻体现在理论方法论的革新与管理决策实践的优化两个层面，不仅突破了传统综合评价的技术局限，更在评价哲学与方法论根基上实现了系统性重构。

1. 理论意义

(1) 深化时序评价的机理探索

当代多指标综合评价的研究，往往侧重于算法优化与参数调适的技术路线，却在一定程度上忽略了对评价内在机理与规范性含义的深入探讨。本研究跳出传统静态截面-动态时序的二元对立的视角，探讨一个更为本质的问题，如何在动态评价中有效区分静态与动态，结构化信息与非结构化扰动的信息源。通过构建结构性趋势与非结构性扰动的解耦机制，本研究实现了从表层技术操作向深层机理挖掘的范式转移，为综合评价注入了方法论自觉。这不仅是对静态评价方法在时间维度上的简单扩展，更是对动态评价的本质思考，为时序场景综合评价指标构建体系提供了新的分析视角。

(2) 优化权重分配的法理性基础

综合评价方法长期面临当量转换的法理性困境，不同指标间的权重分配缺乏充分的社会经济意

义支撑。传统方法基于变异即信息的隐含假设，将指标变异性直接等同于信息含量，忽视变异背后的结构性与非结构性成分的信息重叠以及扰动。本研究尝试提出：权重分配应更多依赖于数据的内在演化规律而非表面统计特征。通过将机器学习作为结构性信息挖掘工具，尝试将权重分配的法理性基础从截面变异度转向时序结构稳定性，为评价结果提供更具解释力的理论支撑。

(3) 时序信息处理的内生化探索

时间维度在综合评价中的处理往往被视为外生的技术问题。本研究尝试将时间价值内生化，探讨其在评价逻辑中的系统性作用。本模型构建了一个双层调节框架，具有清晰的评价哲学含义：DCI-MLTA 模型通过双重调节机制实现对不同评价情境的灵活适配。顶层调节由参数 α 控制，它决定了模型在多大程度上引入时间维度信息；当 α→1 时，模型退化为传统熵权法，其权重完全基于原始数据的当期变异程度，适用于关注当期混合表现的绩效考核等场景；而当 α→0 时，模型则完全依赖于动态权重，侧重于动态稳健性，适用于需要剥离短期非结构性扰动的战略评估或政策效果追踪。内层调节则由参数 λ 主导，它决定了动态权重内部的信息构成偏好；当 λ→1 时，时间注意力机制更关注结构性趋势的拐点，适用于评估长期发展能力；反之，当 λ→0 时，模型则对由残差表征的非结构性扰动更为敏感，更适用于评估系统应对突发危机的韧性。这种顶层-内层相结合的双重调节框架，使模型能够在静态截面评价与动态时间评价之间构建一个综合考虑的评价框架，将时间价值从外生假设转变为内生于评价过程的结构性要素。

2. 实践意义

(1)增强评价结果的决策相关性

综合评价在管理实践中常面临评价的全面性与结果的单一指向性矛盾。传统指标体系因对短期波动过度敏感而难以提供稳定的决策依据。本研究通过结构性与非结构性成分的解耦，增强了评价结果对长期趋势的捕捉能力。动态权重机制使评价体系能够根据不同场景处理短期非结构性扰动，更准确地反映评价对象的基本面与演进趋势，为管理者提供更具稳定性和前瞻性的决策参考，有效弥合了评价结果与战略决策之间的衔接断层。

(2) 评价框架的可解释性增强

本研究通过构建参数化的双通道赋权机制，显著提升了评价过程的透明度与可解释性，并以此为基础拓展了评价方法的政策实验功能。传统综合评价方法常因黑箱特性而面临信任挑战，其根源在于评价逻辑的不透明。而在 DCI-MLTA 框架下，决策者能够通过分析 α（静态-动态平衡）和 λ（趋势-扰动权衡）两个核心参数的取值，清晰理解评价结果背后的逻辑构成——是更依赖于当期表现还是历史轨迹？是侧重于结构性成长还是应对外部冲击？这种深刻的可解释性不仅增强了评价结果的可信度，更为关键的是，它可以作为政策实验工具，决策者可以通过系统性地调整 α 和 λ 参数，在虚拟环境中模拟不同评价导向下的政策效果，预判政策调整可能带来的评价结果变化。例如，通过参数模拟，可以识别出提升区域竞争力是应优先改善短期绩效（调高 α），还是着力于长期结构性变革（调低 α）；是应关注趋势性指标的持续改善（调高 λ），还是提升应对突发事件的响应能力（调低 λ）。这种评价-模拟-优化的闭环，使综合评价从单向度的绩效度量工具，转变为政策设计与优化的动态实验平台，为循证政策制定提供了更为交互、更具前瞻性的决策支持环境。

综上所述，本研究不仅在技术层面实现了动态综合评价方法的创新，更在方法论层面回应了综合评价领域的根本性挑战。通过回归评价的本质——对复杂现象的科学把握与前瞻判断，本研究将综合评价从技术操作提升至方法论自觉的高度，为构建更具法理性、透明度与情境适应性的评价体系提供了理论基础与实践框架。

1.3 国内外研究现状

1.3.1.国外研究现状

国外多指标综合评价研究已从传统静态分析，逐步转向对动态时序数据的深度探索，核心聚焦于破解静态方法在时间维度的局限——如权重稳定性不足、趋势刻画能力薄弱等问题，以提升评价结果的稳健性。这一发展脉络既依托早期理论基础，又在近年形成明确的创新方向。

2008 年，OECD 发布的相关手册奠定了复合指标（Composite Indicators）的规范框架[1]，为后

续研究提供了方法论基础。随着时序数据应用场景的拓展，传统框架的局限性日益凸显，2019 年起，学界开始针对性探索动态扩展路径。Mazziotta 和 Pareto（2019）扩展其提出的 Mazziotta-Pareto Index（MPI），创新构建调整后的非补偿性动态指标方法，通过罚函数机制调节权重在不同时期的敏感度，有效减少短期波动对综合指数的干扰[2]。该方法明确了动态评价的非聚合路径，但仍依赖手动调整时间权重，存在自适应不足的问题。随后，Kuc-Czarnecka 等（2020）将多维动态指标应用于能源贫困评估，重点分析时序数据的趋势分离难题，通过敏感性分析量化权重不稳风险，并提出采用蒙特卡洛模拟验证动态框架鲁棒性[3]，进一步强化了时序不确定性的应对意识，但未深入探索时间维度的自适应调节机制。

2021 年起，动态复合指标研究进入统计建模与算法创新的深化阶段，Cavicchia 与 Vichi（2021）基于模型驱动的复合指标构建框架，通过显式刻画指标结构与潜在一致性约束，实现了对综合指标形成机制的系统建模，从而增强了复合指标在政策跟踪与跨期比较中的结构稳健性与解释一致性。[4]；Mazziotta 与 Pareto（2024）指出，在基于主成分的综合指标构建中，如果未考虑潜在的测量模型如形成性模型 vs 反射模型，可能导致错误的评价结果，因此应结合理论框架与数据特征进行多维验证[5]，二者从不同维度完善了动态评价的技术路径。2022 至 2024 年，实证应用与理论框架的双向突破成为研究重点。Greco 等（2022）在相关综述研究中，将权重优化作为时序环境下的核心议题，采用数据包络分析（DEA）完成巴西水电站绩效的动态评价实证，证实动态权重在实践中的必要性，同时指出时间重要性量化仍需改进[6]。在此基础上，D'Amico 和 Vitale（2023）提出基于函数型数据分析（FDA）的构建方法，通过整体曲线建模强化长期趋势刻画能力，有效提升跨期可比性[7]；Pinar 与 Saisana（2024）进一步提出轨迹稳定性（trajectory stability）框架，建立复合指标在时间序列下的排序一致性与结构稳健性检验标准，为动态指数提供了全新的可靠性衡量维度[8]。

当前，复合指标研究已明确形成时间动态与稳健性并重"的核心方向：方法学层面，全局敏感性分析（GSA）的应用日益广泛，通过检验权重设定与聚合方案对指标稳定性、排序稳健性的影响，形成以敏感度为依据的权重生成与阈值检验体系，实现参数变化影响量化与脆弱点定位[9]；技术路径层面，函数型数据分析与 Malmquist 类指数的引入，成为刻画长期趋势、提升跨期可比性与轨迹解释性的关键手段[10]。这一发展趋势与国际政策导向高度契合，Beyond GDP 议程及相关统计制度更新强调超越单一 GDP 的多维度衡量标准，同时明确时间一致性与可比性要求，为复合指标的动态化发展及治理领域应用提供了方向性约束。

1.3.2.国内研究现状

国内多指标综合评价研究基础扎实，学者们在动态时序问题上取得显著进展，受国外方法论影响，同时注重本土机理反思，如邱东的测度陷阱和苏为华的赋权创新。重点关注时序数据的权重不稳、结构不确定性，以及动态赋权方法的构建。

邱东（2018）梳理宏观经济指标的测度原则及其之间关系；围绕生活质量测度的可行性、必要性及可持续发展测度的观念前提作出反思，指出其中存在的可加性疑点，并系统剖析了目前流行的不同类别方法的测度机理[11]。随后，王筱明等（2020）在构建城市土地利用效益动态评价模型时，充分考虑了时间因素对评价结果的影响，创新性地引入了时间动态权重机制。具体而言，作者采用等差数列赋权法确定各年份的时间权重，遵循时间越近，权重越大的原则，以体现土地利用效益随时间演变的动态特征[12]。何赟等（2025）构建了包含安全、高效等维度的中欧班列高质量发展动态评价体系，通过基于时间序列的主基底分析精简指标，采用梯形模糊熵法赋权，并结合联系度的动态 TOPSIS 法实现现状与潜力的综合评估[13]。谢艾玉等（2025）提出变异系数动态赋权与梯形-三角混合隶属度函数耦合模型，以变异系数量化水质指标波动性并动态调节主客观权重，提升了湖泊水质评价的时空敏感性与准确性[14]。2025 年，邱东等在《统计研究》上从方法到方法论提升，剖析当量转换等动态陷阱，建议注重时序自适应以解决结构不确定性[15]。

1.3.3.文献评述

综上所述，多指标综合评价体系构建领域已积累了丰厚的理论与实证基础，为本研究提供了重要的思想源流与方法论支撑。首先，在方法论反思层面，本研究深切延承了邱东教授关于测度陷阱与可加性疑点的理论警示，以及国外学者关于超越单纯聚合（Beyond GDP）的呼吁。现有的尝试，如 Mazziotta 等引入罚函数机制以应对时序波动、Kuc-Czarnecka 等对趋势分离的初步探讨，实际上

已经敏锐捕捉到了“变异即信息”这一传统赋权逻辑在动态环境下的局限性。然而，这些先行研究多停留在对波动进行外部“惩罚”或被动“适应”的层面，尚未在模型内核中通过显式参数化的方式来探索结构性趋势与非结构性扰动的混淆问题。其次，在技术实现层面，王筱明、谢艾玉等国内学者在时间动态赋权上的探索，确立了时间越近、价值越高或基于波动调节权重的基本范式，为动态评价奠定了基础。但现行方法多依赖预设的函数规则如等差数列、变异系数，缺乏对数据内部时序特征的自适应捕捉能力，难以实现 Greco 等所强调的真正鲁棒性。本研究正是在此基础上，提出基于机器学习与时间注意力的动态综合指数模型（DCI-MLTA）。该模型通过双层调节框架，顶层参数 α 控制静态-动态信息平衡，内层参数 λ 管理趋势-扰动信息构成，实现了对结构性趋势与非结构性扰动的系统解耦。这一设计不仅突破了传统方法"变异即信息"的简化假设，将权重分配的法理性基础从截面变异度转向时序结构稳定性，更通过参数化机制增强了评价过程的透明度与可解释性，使综合评价从单向度的绩效度量工具转变为政策设计与优化的实验平台。DCI-MLTA 模型通过深化时间自适应权重机制，为时序数据下的多指标综合评价提供了更具机理支撑与决策相关性的创新路径。

1.4 研究内容与技术路线

1.4.1 研究内容

一、动态综合评价研究现状的系统性评析

本研究首先对国内外动态综合评价研究进行系统性文献梳理与评析。在理论层面，深入剖析现有方法在时序数据处理方面的根本局限——即传统静态评价方法如熵权法、TOPSIS 等基于独立同分布的隐含假设，无法有效区分结构性趋势与随机性扰动，导致权重分配对短期波动过度敏感或对长期趋势系统性忽视；在方法层面，系统比较现有动态评价方法如相对熵距离改进 TOPSIS、多源异构数据融合框架等的技术路径与适用边界，明确指出它们仍主要侧重于评价体系的时序延展或静态指标的动态加权设计，缺乏对时序数据生成机制的深度解析。基于此，本研究提出趋势-扰动解耦与时间价值内生化的理论突破方向，尝试为动态评价研究提供新的分析框架。

二、基于机器学习与时间注意力的动态综合指数模型构建

本研究的核心内容是构建基于机器学习与时间注意力的动态综合指数模型(DCI-MLTA)。该模型创新性地设计了一个双层调节的权重生成框架：在顶层，通过参数 α 调节静态权重与动态权重的平衡，实现从静态截面评价到动态时间评价的动态调节新视角；在内层，动态权重进一步分解为趋势信息通道与扰动信息通道，通过参数 λ 调节二者相对重要性，并引入时间注意力函数自适应识别关键时间点。模型构建严格遵循信息-注意力严格匹配原则，即趋势注意力仅作用于趋势信息，避免了信息重叠的混淆。并证明了该模型在四类典型宏观演化模式，凹型增长、凸型增长、线性演进与周期性波动下的自适应性与稳健性，为模型的理论有效性提供坚实支撑。

三、模型机理的仿真验证与敏感性分析

为系统验证 DCI-MLTA 模型的动态性能，本研究设计了严谨的蒙特卡洛仿真实验。实验采用滚动窗口设计，对比评估四种权重确定方法，原始熵权法、基于指数时间注意力的改进 EWM、基于机器学习序列建模的改进 EWM、完整 DCI-MLTA 模型，在稳定性与区分度两个维度的表现。稳定性检验考察权重对时间窗口扩展的鲁棒性；区分度检验则通过三类结构化扰动，局部持续性增长、全局短期冲击、结构性趋势转变来评估模型对不同性质信息的响应能力。并开展参数敏感性分析，系统考察 α 与 λ 参数在不同数据结构下的最优配置，提炼出情境-参数匹配的理论框架，建立四象限决策指导矩阵，为模型的实际应用提供参数选择依据。

四、面向碳排放管理的实证应用与决策支持效能验证

本研究选取 2010－2022 年中国 30 个省级行政区的面板数据，构建滚动决策支持与面板固定效应回归相结合的双重验证框架，实证检验 DCI-MLTA 模型的决策支持价值。首先，基于历史信息生成综合发展决策信号；其次，通过面板固定效应模型检验该信号对下一年碳排放的解释力，并控制各省份不随时间变化的固有特征。这一设计跳出传统的内部一致性检验，从外部有效性角度验证了模型的实用价值。同时，通过对比不同机器学习模型挖掘时间趋势的表现，为模型在不同应用场景下的优化配置提供实证依据。

1.4.2 技术路线

本研究遵循提出问题—理论构建—机理验证—实证检验—研究结论的递进逻辑展开技术实施：首先通过系统性文献评析分析现有动态综合评价方法的理论局限，明确趋势-扰动解耦与时间价值内生化的改进方向；继而构建基于机器学习与时间注意力的双层权重调节模型（DCI-MLTA），通过参数α实现静态-动态评价平衡、参数λ分解趋势-扰动信息权重，并嵌入时间注意力函数识别关键时点；最终依托蒙特卡洛仿真实验与中国省级碳排放管理实证，验证模型稳定性、区分度及决策支持效能，如图 1 所示

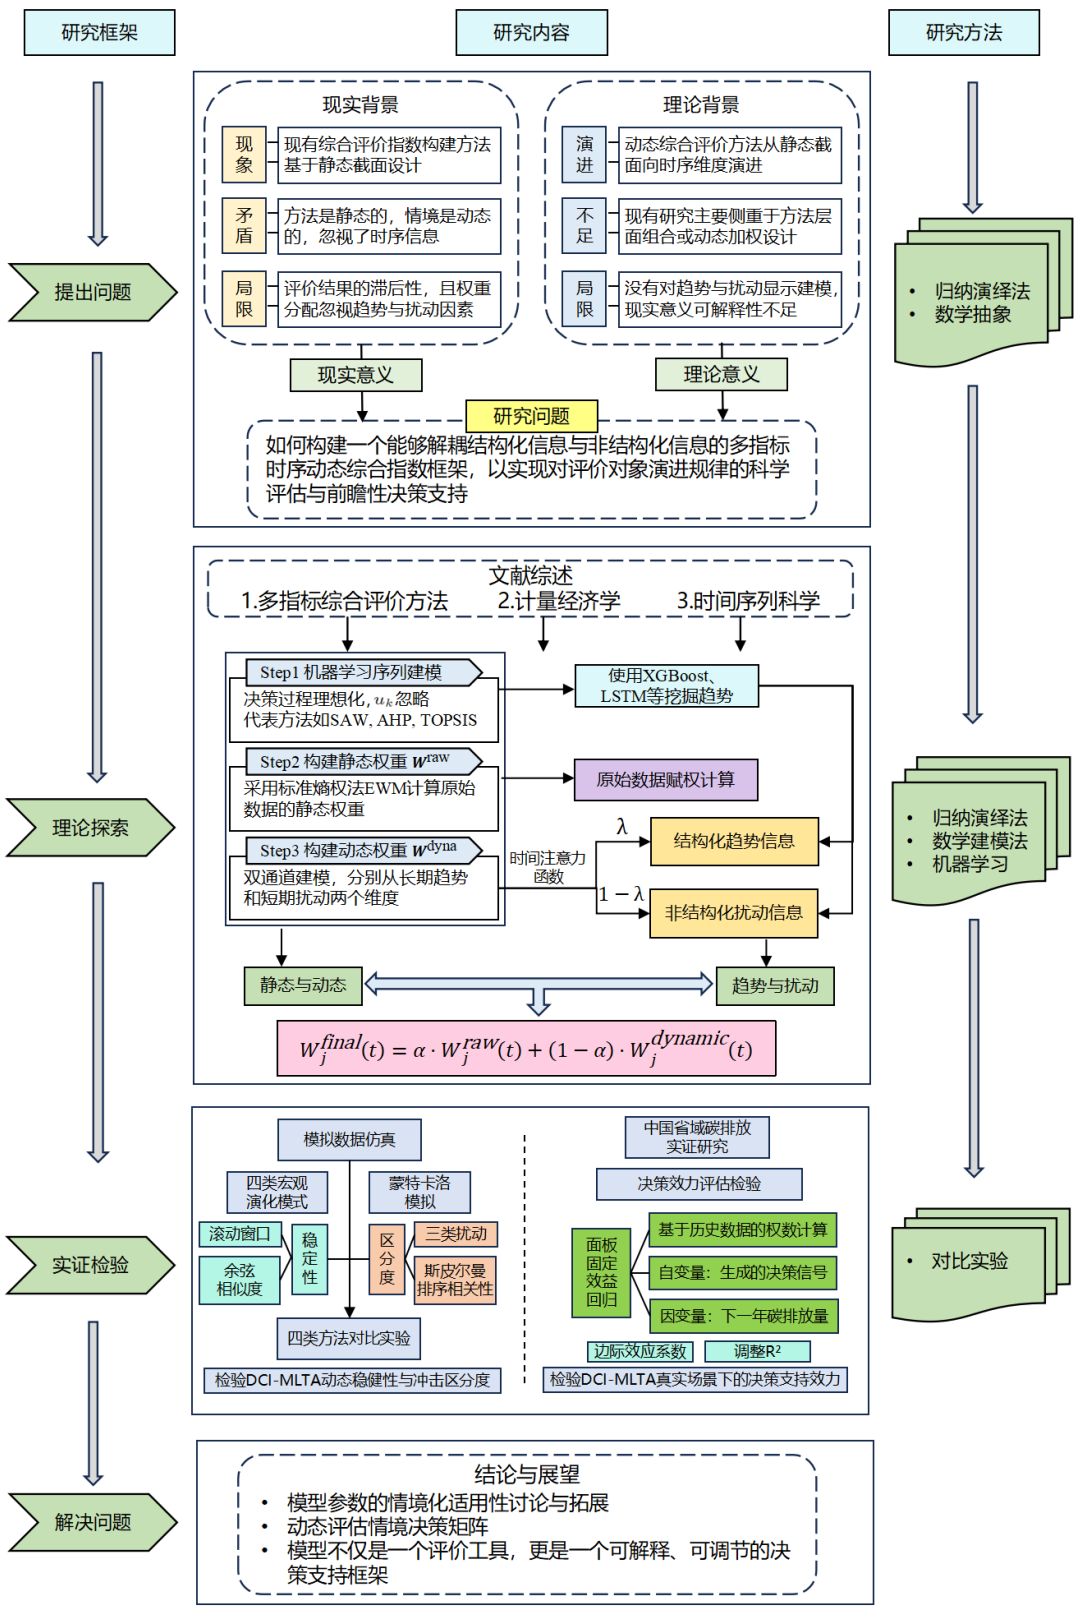

图 1：技术路线图

1.4.3 研究方法

一、文献分析法

本研究采用系统性文献综述（Systematic Literature Review）方法，分析了管理科学、计量经济学与计算机科学三大领域，重点梳理综合评价、时间序列分解及注意力机制等相关理论。通过跨学科交叉印证，厘清结构性趋势与非结构性扰动在动态评价中的本质差异，为模型构建奠定了理论依据与概念框架。

二、数学建模法与机器学习

本研究将非观测成分模型（UCM）的分量思想、熵权法的信息度量原理与时间注意力机制相结合，构建 DCI-MLTA 动态综合指数的数学表达体系。通过严格推导，证明所设计的时间注意力函数在凹型增长、凸型增长、线性演进与周期性波动四类典型演化模式下具有自适应权重分配特性，确保模型兼具理论严谨性与动态响应能力，避免陷入黑箱式算法设计。

三、蒙特卡洛仿真与对照实验法

为系统评估模型性能，本研究设计仿真实验，生成对象，指标和时间三维面板数据，嵌入四类演化模式与三类结构化扰动。采用滚动窗口策略与蒙特卡洛重复，以余弦相似度与斯皮尔曼等级相关系数为评估指标，检验权重稳定性与信息区分度，并通过反事实对照揭示各模型组件的边际贡献。

四、面板实证分析与外部效度验证方法

在实证层面，本研究构建滚动预测与面板固定效应双重验证框架：一方面利用历史数据生成样本外决策信号，避免前视偏误；另一方面通过固定效应模型控制个体不可观测异质性，识别综合指数对碳排放的净影响。该方法不局限于传统内部一致性检验，从外部预测效能与政策解释力角度验证模型的决策支持价值。

1.5 创新点

本研究的创新点主要体现在以下三个方面：

第一，提出了一个融合结构性分解与时间注意力的动态综合评价新框架。本研究摒弃了将时序数据视为混合整体的传统处理方式，而是首先利用机器学习技术将其解耦为趋势性成分与扰动性成分，并分别为二者构建独立的评价通道。这种分而治之的思路，为清晰界定并分别测度长期结构力量与短期随机冲击对指标重要性的影响提供了可能。

第二，设计了一种内生化的时间注意力函数。该函数通过综合考量趋势成分的变化率与扰动成分的幅度，能够以数据驱动的方式自动识别并放大关键时间点在评价中的重要性，实现了权重在时间维度上的自适应调节，克服了传统方法需预设时间权重或等权处理时间点的局限性。

第三，建立了一个具有清晰哲学含义的双层参数调节机制。模型通过顶层参数 α 控制静态信息与动态信息的偏好，回答是否关注动态的评价观问题；通过内层参数 λ 控制趋势信息与扰动信息的构成，回答关注何种动态的侧重点问题。这种设计使得模型能够灵活适配从短期绩效考评到长期战略评估等不同应用场景，增强了综合评价方法的情境适应性。

第二章 相关理论

2.1 综合指标体系构建研究

2.1.1 无量纲化方法

无量纲化是数据处理的核心环节，其目的是消除指标间量纲和数量级差异，使各指标具有可比性。根据是否考虑时间维度，无量纲化方法可分为静态方法和动态方法。

静态无量纲化方法是综合指标评价体系构建过程中最常用的数据处理方法，它们仅考虑当前数据分布特征，忽略时间维度上的变化趋势。常见的静态无量纲化方法包括：

（1）极差标准化法（Max-Min 标准化）：最常用的无量纲化方法之一，其公式为：

$$x_{ij}^{*} = \frac{x_{ij} - \min_j(x_{ij})}{\max_j(x_{ij}) - \min_j(x_{ij})}$$

该方法将数据线性映射到[0,1]区间，保留了原始数据的分布特征。然而，极差标准化对异常值敏感，且当新数据加入时，可能需要重新计算最大值和最小值。

（2）Z-score 标准化法：Z-score 标准化基于数据的均值和标准差进行标准化，其公式为：

$$x_{ij}^{*} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

其中，μ_j和σ_j分别表示第 j 个指标的均值和标准差。Z-score 标准化处理后的数据均值为 0，标准差为 1，适用于数据分布近似正态的情况。该方法对异常值的敏感性较低，但处理后的数据可能不在固定区间内。

（3）向量标准化法：向量标准化将每个指标值除以该指标的欧几里得范数，其公式为：

$$x_{ij}^{*}=\frac{x_{ij}}{\sqrt{\sum_{i=1}^{m}x_{ij}^{2}}}$$

该方法处理后的数据向量长度为 1，适用于需要保持数据方向信息的场景。

静态无量纲化方法简单易用，但它们忽略了时间维度上的变化趋势，无法反映指标的发展动态。在动态评估场景中，这些方法可能导致评估结果缺乏前瞻性和动态适应性。

动态无量纲化方法在静态方法的基础上，引入了时间维度，考虑了指标的历史变化趋势和未来发展预期。常见的动态无量纲化方法包括：

（1）标准序列法：标准序列法首先对时间序列数据进行降维处理，然后进行无量纲化，最后依据当前时刻调整比例关系。其具体步骤如下：

Step1：降维处理：平均合成

$$x_{ij}{}'=\frac{1}{p}\sum_{q=1}^{p}x_{ij}\left(t_q\right)$$

Step2：无量纲化处理

$$x_{ij}^{*}=c+\frac{x_{ij}{}'-\min_i\{x_{ij}{}'\}}{\max_i\{x_{ij}{}'\}-\min_i\{x_{ij}{}'\}}\times d$$

Step3：依据时刻 T 调整比例关系

$$f_{ij}\left(t_q\right)=x_{ij}^{*}\cdot\frac{x_{ij}\left(t_q\right)}{x_{ij}{}'}$$

标准序列法通过当前时刻数据与平均值的比例关系调整无量纲化结果，实现了对时间维度的部分考虑。然而，该方法主要基于历史数据，缺乏对未来趋势的预测和融入。

（2）全序列法：全序列法将同一指标在不同时点的数据集中起来，对整个时间序列数据统一进行无量纲化处理。其公式为：

$$f_{ij}\left(t_q\right)=c+\frac{x_{ij}\left(t_q\right)-\min_{i,q}\{x_{ij}\left(t_q\right)\}}{\max_{i,q}\{x_{ij}\left(t_q\right)\}-\min_{i,q}\{x_{ij}\left(t_q\right)\}}\times d$$

全序列法保留了各指标自身历史波动范围，并在全时序上统一尺度，适用于希望保持历史数据相对关系的场景。然而，该方法同样缺乏对未来趋势的考虑，无法实现前瞻性评估。

（3）增量权功效系数法：增量权功效系数法是对静态无量纲化结果与动态增量无量纲化结果进行加权合成，以同时反映指标的当前水平和变化趋势。其公式为：

$$f_{ij}\left(t_q\right)=\alpha\cdot g_{ij}\left(t_q\right)+(1-\alpha)\cdot h_{ij}\left(t_q\right)$$

其中：$g_{ij}\left(t_q\right)$是静态无量纲化结果$g_{ij}\left(t_q\right)=c+\frac{x_{ij}\left(t_q\right)-\min_{i,q}\{x_{ij}\left(t_q\right)\}}{\max_{i,q}\{x_{ij}\left(t_q\right)\}-\min_{i,q}\{x_{ij}\left(t_q\right)\}}\times d$；$h_{ij}\left(t_q\right)$是动态增量无量纲化结果$h_{ij}\left(t_q\right)=c+\frac{\Delta x_{ij}\left(t_q\right)-\min_{i,q}\{\Delta x_{ij}\left(t_q\right)\}}{\max_{i,q}\{\Delta x_{ij}\left(t_q\right)\}-\min_{i,q}\{\Delta x_{ij}\left(t_q\right)\}}\times d$；$\Delta x_{ij}\left(t_q\right)=x_{ij}\left(t_r\right)-x_{ij}\left(t_s\right)$表示相邻或指定两个时刻之间的增量。

增量权功效系数法通过参数α灵活调节静态与动态部分的重要性，能够同时考虑指标的当前水平和变化趋势。然而，该方法主要基于历史变化趋势，缺乏对未来趋势的预测和融入。

动态无量纲化方法在静态方法的基础上引入了时间维度，能够更好地反映指标的发展动态。然而，现有方法主要基于历史数据，缺乏对未来趋势的预测和融入，难以实现真正意义上的前瞻性评估。

2.1.2 客观权数理论

权重求解是综合指标评价体系构建的核心环节，其目标是通过量化各准则的相对重要性，为综合评估提供依据。客观权重法完全基于数据内在特征（如变异程度、相关性等）确定权重，有效规避了主观判断的潜在偏误。根据原理差异，主流客观权重方法可分为基于信息熵、统计相关性、序列关联性以及数据降维等类型。

（1）熵权法（Entropy Weight Method）

熵权法源于信息论，以信息熵度量指标的离散程度：熵值越小，表明该指标在不同方案间的差异越显著，所提供的信息量越大，权重也应越高（Shannon, 1948）。其计算步骤如下：

Step1：数据标准化：对原始矩阵进行比重化处理（假设为正向指标）：

$$p_{ij} = \frac{x_{ij}}{\sum_{i=1}^{m} x_{ij}}$$

Step2：计算信息熵：

$$e_j = -\frac{1}{\ln m}\sum_{i=1}^{m} p_{ij}\ln p_{ij} \quad \left(\text{若 } p_{ij} = 0,\text{则令 } p_{ij}\ln p_{ij} = 0\right)$$

Step3：计算差异系数：

$$g_j = 1 - e_j$$

Step4：确定权重：

$$w_j = \frac{g_j}{\sum_{j=1}^{n} g_j}$$

熵权法具有完全客观、计算简便的优点，尤其适用于指标值差异显著的场景。然而，其权重完全依赖于数据离散程度，若指标间存在较强相关性，可能造成信息重复计算，导致权重分配失真。

（2）CRITIC 法（Criteria Importance Through Intercriteria Correlation）

CRITIC 法从对比强度与冲突性两个维度综合评估指标的信息载量（Diakoulaki et al., 1995）。对比强度以标准差度量，表征指标取值的波动幅度；冲突性以指标与其他指标的相关性之和度量，反映其独立信息贡献程度。

Step1：数据标准化（极差法）：

$$r_{ij} = \frac{x_{ij} - \min_i x_{ij}}{\max_i x_{ij} - \min_i x_{ij}}$$

Step2：计算对比强度（标准差）：

$$\sigma_j = \sqrt{\frac{1}{m-1}\sum_{i=1}^{m}\left(r_{ij} - \bar{r}_j\right)^2}$$

Step3：计算冲突性（基于相关系数矩阵）：

$$R_j = \sum_{k=1}^{n}\left(1 - |\rho_{jk}|\right)$$

其中 ρ_{jk} 为指标 j 与 k 的皮尔逊相关系数。

Step4：计算信息量：

$C_j = \sigma_j \cdot R_j$

Step5：确定权重：

$$w_j = \frac{C_j}{\sum_{j=1}^{n} C_j}$$

CRITIC 法兼顾指标内变异与指标间相关性，权重分配更为全面合理。但其结果对相关系数较为敏感，当指标数量较少或相关性较弱时，稳定性可能下降。

（3）灰色关联分析法（Grey Relational Analysis）

灰色关联分析法基于灰色系统理论，通过计算各比较序列与参考序列（理想序列）的关联度，衡量其变化趋势的相似性（邓聚龙，1982）。关联度越高，表明该指标与理想状态越接近，权重越大。

Step1：确定参考序列 x_0：通常由各指标的最优值（极大值或极小值，依属性而定）构成：

$x_0 = \{\max_i x_{i1}, \max_i x_{i2}, \ldots, \max_i x_{in}\}$ （针对效益型指标）

Step2：计算关联系数：

$$\gamma_{0j}(i) = \frac{\min_i \min_j |x_0(j) - x_i(j)| + \rho \max_i \max_j |x_0(j) - x_i(j)|}{|x_0(j) - x_i(j)| + \rho \max_i \max_j |x_0(j) - x_i(j)|}$$

其中 $\rho \in (0,1)$ 为分辨系数，通常取 0.5。

Step3：计算关联度（均值）：

$$\gamma_j = \frac{1}{m} \sum_{i=1}^{m} \gamma_{0j}(i)$$

Step4：确定权重：

$$w_j = \frac{\gamma_j}{\sum_{j=1}^{n} \gamma_j}$$

灰色关联法对数据分布无严格要求，适用于小样本、贫信息系统。但其权重受参考序列选择影响显著，若理想值设定不合理，可能导致评价偏差。

（4）主成分分析法（Principal Component Analysis）

主成分分析法通过正交变换将原有相关指标转化为一组互不相关的主成分，并依据各主成分的方差贡献率确定权重（Jolliffe, 2002）。其本质是一种降维技术，旨在用少数综合变量替代原始变量集。

Step1：数据标准化（Z-score）：

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

Step2：计算相关系数矩阵 R：

$$R = \frac{1}{m-1} Z^T Z$$

Step3：特征分解：求解特征方程 $|R - \lambda I| = 0$，得到特征值 $\lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_n \geq 0$ 及对应的特征向量 $a_1, a_2, \ldots, a_n$。

Step4：计算方差贡献率：

$$\alpha_k = \frac{\lambda_k}{\sum_{j=1}^{n} \lambda_j}$$

Step5：确定主成分个数 p：通常保留累积贡献率（如 $\sum_{k=1}^{p} \alpha_k \geq 85\%$）的主成分。

Step6：计算权重：基于主成分载荷与贡献率合成：

$$w_j = \frac{\sum_{k=1}^{p} |a_{kj}| \alpha_k}{\sum_{j=1}^{n} \sum_{k=1}^{p} |a_{kj}| \alpha_k}$$

主成分法能有效消除多重共线性，降低数据维度，适用于高维指标体系。然而，权重意义不如

前述方法直观，且要求数据满足近似多元正态分布，否则主成分的实际含义难以解释。

2.2 机器学习

预测是获取未来趋势信息的关键途径，机器学习方法凭借其强大的模式识别与非线性拟合能力，在时间序列预测领域展现出显著优势。根据模型原理与结构复杂度，可将其划分为统计学方法、传统机器学习方法及深度学习方法三大类。

2.2.1 统计模型

统计学方法以概率论与数理统计为理论基础，模型结构严谨，解释性强，适用于具有明显规律性的时间序列。以自回归积分滑动平均模型（ARIMA）为例：是处理非平稳时间序列的经典方法，通过差分使序列平稳，再结合自回归（AR）与移动平均（MA）项进行建模（Box & Jenkins, 1970）。其一般形式为 ARIMA(p,d,q)：

自回归项（AR）：描述当前值与历史值的关系：

$$X_t = c + \sum_{i=1}^{p} \phi_i X_{t-i} + \varepsilon_t$$

积分项（I）：通过 d 阶差分使序列平稳：

$Y_t = (1 - L)^d X_t$

移动平均项（MA）：描述当前值与历史误差的关系：

$$X_t = \mu + \varepsilon_t + \sum_{i=1}^{q} \theta_i \varepsilon_{t-i}$$

其中 L 为滞后算子，ε_t 为白噪声。ARIMA 模型参数意义明确，计算效率高，适用于线性、平稳或可差分平稳的序列。但其难以捕捉复杂非线性特征，对突变型序列预测效果有限。

2.2.2 机器学习模型

传统机器学习方法通过算法从数据中自动学习预测规则，具有较强的非线性拟合能力。以梯度提升机为例：XGBoost（eXtreme Gradient Boosting）是一种高效的梯度提升决策树算法，通过迭代地构建弱学习器（决策树）并优化加权组合来提升预测性能（Chen & Guestrin, 2016）。其核心思想是最小化包含损失函数与正则项的目标函数：

$$\mathrm{Obj}^{(t)} = \sum_{i=1}^{n} l\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \Omega(f_t)$$

其中正则化项 $\Omega(f_t) = \gamma T + \frac{1}{2}\lambda \parallel w \parallel^2$ 控制模型复杂度。通过二阶泰勒展开近似目标函数：

$$\mathrm{Obj}^{(t)} \approx \sum_{i=1}^{n} \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)\right] + \Omega(f_t)$$

其中 g_i, h_i 为一阶、二阶导数。XGBoost 支持并行计算，内置正则化与缺失值处理，在结构化数据预测中表现卓越。

2.2.3 深度学习模型

深度学习方法利用深层神经网络自动提取数据的层次特征，尤其擅长处理序列数据中的长期依赖关系。以长短期记忆网络（LSTM）为例：通过引入门控机制（遗忘门、输入门、输出门）有效缓解梯度消失/爆炸问题，适于长序列建模（Hochreiter & Schmidhuber, 1997）。其单时间步计算过程如

下：

Step1：遗忘门：控制上一时刻细胞状态的保留程度：

$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right)$

Step2：输入门：控制当前新信息的写入程度：

$i_t \quad = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$

$\tilde{C}_t \quad = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$

Step3：细胞状态更新：

$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$

Step4：输出门：控制当前细胞状态的输出程度：

$o_t \quad = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$

$h_t \quad = o_t \odot \tanh(C_t)$

LSTM 能够捕捉长期时间依赖关系，对非线性、非平稳序列具有强大建模能力。但其计算成本较高，需大量数据训练，且模型解释性较差。

2.3 评述

通过对综合指标体系构建与机器学习应用相关理论的回顾梳理，可以得出以下结论：（1）综合指标评价体系在处理时序数据时，面临一个核心方法论挑战：**信息重叠与结构不确定性**。如 2.1 节所述，尽管动态评价方法通过引入时间维度改进了静态框架的局限性，但其底层逻辑通常将每个时点的原始观测值视为一个整体进行权重计算。熵权法等客观赋权法依据的是各时点截面上指标值的变异程度。问题在于，原始观测序列是长期结构性趋势与短期随机性扰动的复合体，这两种成分在经济含义上截然不同，其相对重要性也随评价场景而变化。例如，战略评估可能更关注长期趋势，而危机响应则需侧重短期波动。传统方法无法有效解析这两种信息，导致信息重叠，其生成的单一权重难以同时清晰表达两种成分的独立影响，从而引发邱东（2025）所指出的结构信息不确定性问题，使得权重经济含义模糊，在不同应用场景下的适用性受限。（2）机器学习技术在时序分析中的强大挖掘能力，为从根源上解决信息重叠问题提供了新的路径，但其在评价模型内部的机理创新中尚未得到深度应用。机器学习模型在捕捉与挖掘序列内在模式、分解趋势与波动成分方面具有显著优势。然而，当前研究多将其作为一个独立的预测工具，其输出结果通常作为评价体系的外部输入，未能将其数据解析能力深度内嵌于综合评价的模型内核，特别是未能用于重构权重确定这一核心机理，以针对不同场景需求区分信息的重要性。 综上所述，现有研究的缺口在于：传统动态评价方法因无法解析时序数据的内在结构而面临信息重叠与结构不确定性困境；而能够有效进行结构分解的机器学习技术，其潜力尚未被系统地用于构建一种能根据场景需求动态区分信息重要性的赋权新机制。因此，本研究的突破口在于：将机器学习从一种外部的预测工具，转变为内生于评价模型的时间趋势挖掘模型，核心思路是利用机器学习对历史数据进行趋势与扰动的成分挖掘分解，进而构建一个能够分别度量不同信息成分的截面区分度，并引入参数机制根据实际场景动态调节其重要性的权重模型。这正是本研究后续章节提出基于机器学习与时间注意力的动态综合指数模型（DCI-MLTA）的理论出发点，该模型旨在通过信息分离与场景化动态加权来解决信息重叠与结构不确定性这一核心问题。

第三章 模型构建与理论分析

3.1 研究框架：基于机器学习与时间注意力的动态综合指数模型

如第一章所述，将为截面数据设计的传统客观赋权法如 EWM 直接应用于时序数据，面临权重对短期扰动过度敏感或者过度忽视的核心挑战。其根本原因在于，原始观测序列 $f(t)$ 是一个复合信息体，它同时包含了系统的长期结构性趋势与短期随机性波动。传统方法无法自动区分这两种信息，导致其权重易受短期噪声的干扰。为解决此问题，本研究构建了一个基于机器学习与时间注意

力的动态综合指数评价模型 (Dynamic Composite Index Model based on Machine Learning and Time Attention, DCI-MLTA)。本模型的核心思路是：将最终的评价权重 W^{final} 划分为两个既独立又互补的部分：静态权重 W^{raw} (Static Weight)： 完全基于原始观测数据 $f(t)$，通过 EWM 计算得出。它反映了当时当地的结构性与扰动性混合信息的截面区分度，包含了趋势与噪声的混合信息。动态权重 W^{dynamic} (Dynamic Weight)： 这是一个经时间注意力调节的权重。它首先通过机器学习（ML）建模数据的长期趋势 $\hat{X}(t)$，捕捉时间趋势信息；然后，计算该趋势的截面区分度；最后，使用本研究设计的时间注意力函数（TSW） ω_t 来调节该区分度在时间维度的重要性。

3.2 基于机器学习的序列建模

DCI-MLTA 模型的基础是对原始时序数据的信息进行有效划分。本研究借鉴 UCM（非观测成分模型）的思想，即任何时间序列 $f(t)$ 均可视为趋势与波动的结合。

定义 3.1 :对于 n 个指标中的任意指标 j（$j = 1, \dots, n$），其在 T 个时期（$t = 1, \dots, T$）的原始观测序列为 $f_{j,t}$。本研究假设存在一个有效训练的机器学习或统计拟合模型（如 LSTM, ARIMA,XGBoost 等），该模型能够对 $f_{j,t}$ 进行拟合，得到：

$$f_{j,t} = \hat{X}_{j,t} + e_{j,t}$$

其中：$\hat{X}_{j,t}$ 为 ML 建模的结构性成分（Structural Component）。该序列代表了由模型捕捉到的、指标 j 的长期趋势演化路径；$e_{j,t}$ 为 残差序列 (Residual Series)，在此定义为非结构性扰动 (Volatility Component)。该序列代表了原始数据中未能被长期趋势解释的短期信息随机性扰动或者外界冲击。这两个分量 $\hat{X}_{j,t}$ 和 $e_{j,t}$ 是后续构建 W^{dynamic} 的基础输入。

3.3 静态权重 W^{raw} 的构建

静态权重 W^{raw} 是模型的基准部分，它采用标准的熵权法 EWM 进行计算。

定义 3.2 (静态权重)：对m个评价对象在n个指标j上的原始数据 $f_{ij,t}$（$i = 1, \dots, m$）进行标准化处理，得到 $x_{ij,t}$。

1.计算第 t 时刻，指标 j 的信息冗余度 $d_j^{\text{raw}}(t)$:

$$d_j^{\text{raw}}(k) = 1 - e_j^{\text{raw}}(k) = 1 - \left(-K \sum_{i=1}^{m} p_{ij}(k) \ln p_{ij}(t) \right)$$

其中 $p_{ij}(k)$ 为标准化后的概率值，$K = \frac{1}{\ln(m)}$。

2.归一化得到静态权重 $W_j^{\text{raw}}(k)$:

$$W_j^{\text{raw}}(k) = \frac{d_j^{\text{raw}}(k)}{\sum_{j=1}^{n} d_j^{\text{raw}}(k)}$$

$W_j^{\text{raw}}(k)$ 反映了原始数据在 k 时刻的截面区分度，但易受短期噪声影响。

3.4 动态信息分量的构建

3.4.1 动态权重 W^{dynamic} 的构成要素测度

动态权重 W^{dynamic} 的构建遵循双通道解耦原则，旨在分别从长期趋势和短期扰动两个维度，精准捕捉指标随时间演化的动态特征。为此，本研究在 3.2 节序列分解的基础上，构建了反映截面区分度的动态信息基底与反映时间重要性的内生时间注意力两类核心组件。

定义 3.3 (动态信息基底，Dynamic Information Base)

为了量化评价对象在不同信息层面的截面差异，分别对结构性成分 $\hat{X}_{ij,t}$ 与非结构性扰动模值 $|e_{ij,t}|$ 应用熵权法流程，定义趋势信息基底 $d_j^{\text{trend}}(t)$ 与扰动信息基底 $d_j^{\text{vol}}(t)$ 如下：

$$\begin{cases} d_j^{\text{trend}}(t) = 1 - e_j^{\text{trend}}(t) \\ d_j^{\text{vol}}(t) = 1 - e_j^{\text{vol}}(t) \end{cases}$$

其中，$e_j^{\text{trend}}(t)$ 与 $e_j^{\text{vol}}(t)$ 分别表示时刻 t 下趋势分量与扰动分量的信息熵。从物理意义上审视，趋势信息基底 $d_j^{\text{trend}}(t)$ 剔除了短期噪声干扰，纯粹反映了各评价对象在长期发展路径上的结构性区分度；而扰动信息基底 $d_j^{\text{vol}}(t)$ 则聚焦于残差序列，刻画了各对象在面对外部冲击或随机波动时的非结构性异质表现。二者共同构成了动态评价的截面信息基础。

定义 3.4 (内生时间注意力，Endogenous Time Attention)

为了实现权重在时间维度上的自适应调节，本研究设计了由数据演化特征驱动的时间注意力函数。对于指标 j 在时刻 t，定义趋势注意力 $A_{j,t}^{\text{trend}}$ 与扰动注意力 $A_{j,t}^{\text{vol}}$ 如下：

$$A_{j,t}^{\text{trend}} = \frac{|\Delta\hat{X}_{j,t}|}{\max_{1\le s\le T}|\Delta\hat{X}_{j,s}|}, \quad A_{j,t}^{\text{vol}} = \frac{|e_{j,t}|}{\max_{1\le s\le T}|e_{j,s}|}$$

其中 $\Delta\hat{X}_{j,t} = \hat{X}_{j,t} - \hat{X}_{j,t-1}$ 为趋势分量的一阶差分，一方面，趋势注意力 $A_{j,t}^{\text{trend}}$ 旨在测度结构性演化的剧烈程度。当 $|\Delta\hat{X}_{j,t}|$ 显著增大时，表征了指标正处于加速增长、急剧衰退或趋势拐点等关键演化窗口，模型通过自适应放大该时段权重，以强化对结构性突变信息的捕捉能力。另一方面，扰动注意力 $A_{j,t}^{\text{vol}}$ 严格锚定于非结构性残差的相对强度。当 $|e_{j,t}|$ 出现异常峰值时，可能系统遭受的重大外部冲击或非预期事件，模型通过提升该时段的敏感度，确保评价结果能够敏锐响应系统的风险承压状态或异常波动信号。

3.4.2 时间注意力组件机理验证

为验证时间注意力组件能否在不同演化机理下自适应识别关键时段，将上述两个部分组合为

$$\omega_{j,t} = \lambda \cdot \frac{|\Delta \hat{X}_{j,t}|}{\max_{1 \le s \le T} |\Delta \hat{X}_{j,s}|} + (1-\lambda) \cdot \frac{|e_{j,t}|}{\max_{1 \le s \le T} |e_{j,s}|}, \quad t = 1,2,\dots,T$$

本文构造四类典型宏观指标生成过程，覆盖边际递减、加速增长、线性演进与中长期周期等基本形态，具体如下。

（1）凹型增长模式（边际递减）

设真实信号为 $f(t) = a - be^{-ct}$（$a, b, c > 0$），观测数据为 $X_t = f(t) + \varepsilon_t$（$\varepsilon_t \sim \text{i.i.d. } N(0, \sigma^2)$）。

由于 $f'(t) = bce^{-ct} > 0$ 且 $f''(t) = -bc^2e^{-ct} < 0$，函数单调递增且增速递减。其一阶差分满足：

$|\Delta f(t)| \approx f'(t) \downarrow$ 随 t 增大而单调递减。

在信噪比足够高（σ 较小）时，拟合值 $\hat{X}_t$ 能有效逼近 $f(t)$，故 $|\Delta \hat{X}_t|$ 亦单调递减。由式(1)（即定义 3.3）可知，ω_t 主要由第一项主导，因此：

$\omega_1 > \omega_2 > \cdots > \omega_T$

即早期时段权重显著高于后期，符合凹型增长中前期变化更具信息价值的经济直觉。

情况1：凹型增长模式（边际递减）

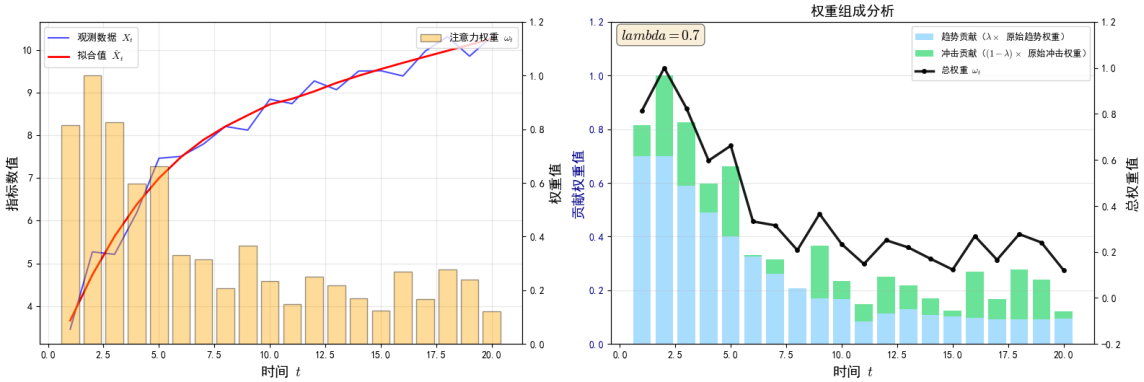

（2）凸型增长模式（加速增长）

设真实信号为 $f(t) = at^k$（$a > 0, k > 1$），观测数据为 $X_t = f(t) + \varepsilon_t$。

此时 $f'(t) = akt^{k-1} \uparrow$，增速随时间递增。一阶差分近似为：

$|\Delta f(t)| \approx f'(t) \uparrow$

同理，在拟合有效前提下，$|\Delta \hat{X}_t|$ 单调递增，故：

$\omega_1 < \omega_2 < \cdots < \omega_T$

即后期时段权重更高，准确捕捉技术爆发或规模效应等加速现象的关键期。

情况2：凸型增长模式（加速增长）

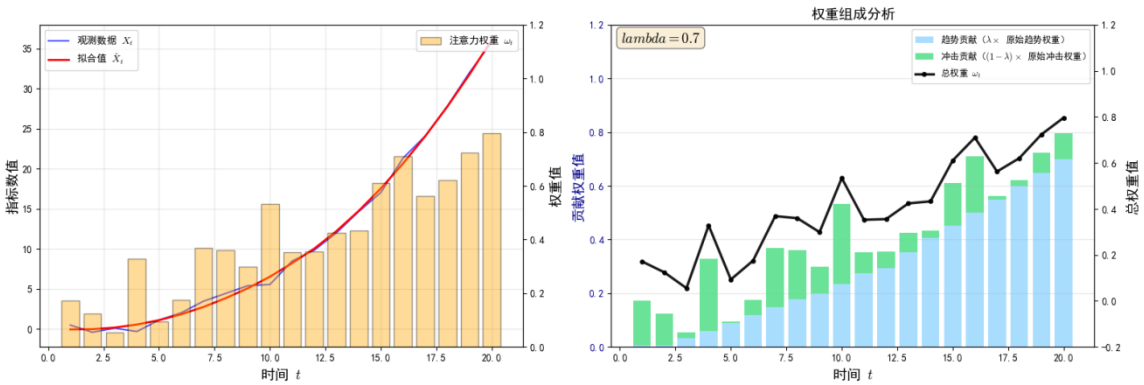

（3）线性趋势模式

设真实信号为严格线性函数 $f(t)=\alpha+\beta t$（$\beta>0$），观测数据为 $X_t=\alpha+\beta t+\varepsilon_t$（$\varepsilon_t\sim \text{i.i.d. } N(0,\sigma^2)$）。

此时，一阶导数 $f'(t)=\beta$ 为常数，故理论趋势变化率恒定。在拟合模型（如 UCM）能有效提取线性趋势的前提下，拟合值满足 $\hat{X}_t\approx\alpha+\beta t$，从而：

$$|\Delta\hat{X}_t|=|\hat{X}_t-\hat{X}_{t-1}|\approx\beta=\text{常数}$$

即第一项 $\frac{|\Delta\hat{X}_t|}{\max|\Delta\hat{X}_s|}\approx 1$ 对所有 t 几乎相等。

同时，由于无结构性突变，残差 $e_t=X_t-\hat{X}_t\approx\varepsilon_t-(\hat{\varepsilon}_t)$ 为零均值平稳序列，其绝对值 $|e_t|$ 在各期波动幅度相近，无系统性高峰。

因此，由定义 3.3 可知：

$$\omega_t\approx\lambda\cdot 1+(1-\lambda)\cdot\frac{|e_t|}{\max|e_s|}\approx\text{近似平稳}$$

即时间注意力权重在全时段分布均匀。这恰与线性趋势的经济含义一致：指标以稳定速率演进，各时期信息价值相当，TSW 函数在此情形下自动退化为近似等权，体现了其自适应性与稳健性。

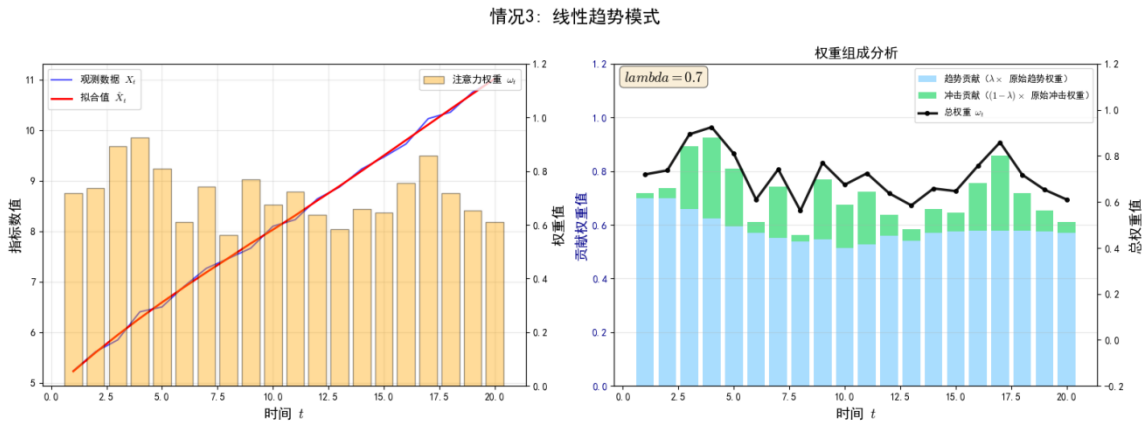

（4）周期性模式（中长期波动）

设真实信号为 $f(t)=A\sin\left(\frac{2\pi t}{T_0}+\phi\right)$，其中周期 T_0 取值较大（如 8–15 年），反映宏观经济中常见的中长期波动，观测数据为 $X_t=f(t)+\varepsilon_t$。

该模式无长期趋势，仅含缓慢的周期性起伏。其一阶导数为 $f'(t)=\frac{2\pi A}{T_0}\cos\left(\frac{2\pi t}{T_0}+\phi\right)$。

故 $|\Delta\hat{X}_t|$ 在正弦函数的波峰与波谷邻域取得局部极大值（因斜率变化最快）。若采用能捕捉周期结构的模型进行拟合，则 $\hat{X}_t$ 可有效还原周期形态，使得 $|\Delta\hat{X}_t|$ 在极值点附近显著升高。同时，若某期受外部冲击，则残差 $|e_t|$ 突增。

因此，ω_t 在两类时刻显著升高：

周期转折点附近（由趋势变化率驱动）；

异常扰动时期（由残差驱动）。

这与宏观指标在中长期波动中的实际动态特征一致。

、

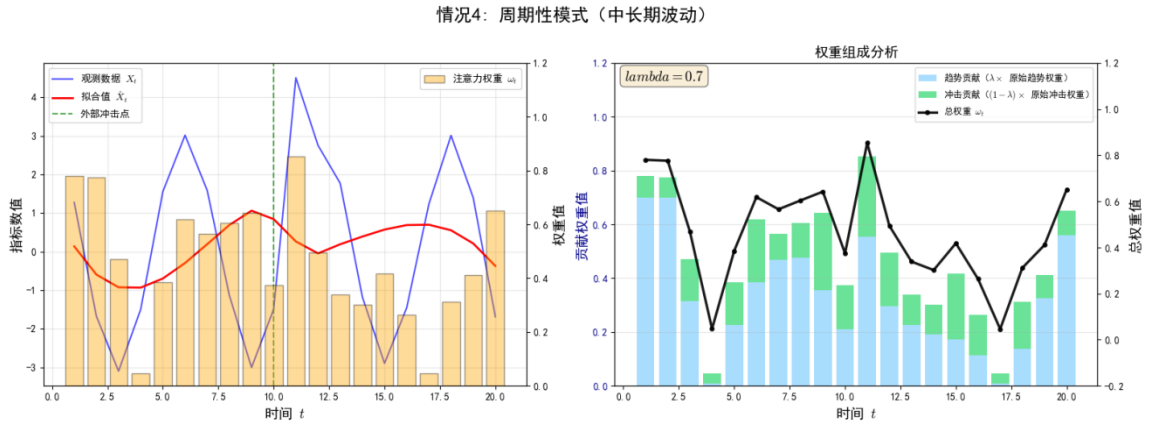

（5）综合讨论

上述四类情形覆盖了宏观指标的主要演化形态。TSW 函数（$\omega_{j,t}$）在每种情形下均能自适应地聚焦于信息含量更高的时段，且无需预设模式类型。其有效性仅依赖一个基本前提：存在适配数据结构的拟合模型 $\hat{X}_{j,t}$。

3.5 动态权重 W^{dynamic} 的构建

定义 3.4 (复合动态信息量):引入趋势-扰动偏好参数 $\lambda \in [0,1]$。指标 j 在 t 时刻的复合动态信息量 $d_j^{\text{dynamic}}(t)$ 定义为：

$$d_j^{\text{dynamic}}(t) = \lambda \cdot \left(A_{j,t}^{\text{trend}} \cdot d_j^{\text{trend}}(t)\right) + (1-\lambda) \cdot \left(A_{j,t}^{\text{vol}} \cdot d_j^{\text{vol}}(t)\right)$$

其中趋势通道$\lambda \cdot \left(A_{j,t}^{\text{trend}} \cdot d_j^{\text{trend}}(t)\right)$表示指标 j 在 t 时刻的趋势信息贡献 等于趋势的截面区分度乘趋势变化的剧烈程度；扰动通道： $(1-\lambda) \cdot \left(A_{j,t}^{\text{vol}} \cdot d_j^{\text{vol}}(t)\right)$表示指标 j 在 t 时刻的扰动信息贡献等于扰动的截面区分度乘扰动幅度的剧烈程度。参数 λ 的作用是调节动态权重内部的信息构成：当 $\lambda \to 1$：动态权重仅由趋势通道决定（关注结构性拐点）；当 $\lambda \to 0$：动态权重仅由扰动通道决定（关注外部冲击）；当 $\lambda = 0.5$：二者平衡贡献。

定义 3.5 动态权重：将复合动态信息量归一化，得到动态权重：

$$W_j^{\text{dynamic}}(t) = \frac{d_j^{\text{dynamic}}(t)}{\sum_{j=1}^{n} d_j^{\text{dynamic}}(t)}$$

3.6 最终模型合成与分析

最终权重 $W_j^{\text{final}}(t)$ 通过引入原始-动态偏好参数 $\alpha \in [0,1]$，对静态权重与动态权重进行线性组合：

定义 3.6 (最终权重):

$$W_j^{\text{final}}(t) = \alpha \cdot W_j^{\text{raw}}(t) + (1-\alpha) \cdot W_j^{\text{dynamic}}(t)$$

本模型构建了一个双层调节框架，具有清晰的评价哲学含义：DCI-MLTA 模型通过双重调节机制实现对不同评价情境的灵活适配。顶层调节由参数 α 控制，它决定了模型在多大程度上引入时间

维度信息；当 α→1 时，模型退化为传统熵权法，其权重完全基于原始数据的当期变异程度，适用于关注当期混合表现的绩效考核等场景；而当 α→0 时，模型则完全依赖于动态权重，侧重于动态稳健性，适用于需要剥离短期噪声的战略评估或政策效果追踪。内层调节则由参数 λ 主导，它决定了动态权重内部的信息构成偏好；当 λ→1 时，时间注意力机制更关注结构性趋势的拐点，适用于评估长期发展能力；反之，当 λ→0 时，模型则对由残差表征的非结构性扰动更为敏感，更适用于评估系统应对突发危机的韧性。这种顶层-内层相结合的双重调节框架，使模型能够在静态截面评价与动态时间评价之间构建一个连续的评价谱系，增强了综合指数的解释力与情境适应性。与传统 EWM 相比，DCI-MLTA 实现了信息源与时间重要性的严格匹配：趋势注意力仅作用于趋势信息，扰动注意力仅作用于扰动信息。这种通道分离机制有效缓解了邱东（2025）所指出的信息重叠与结构信息不确定性问题，使综合评价更贴近社会经济意义上的可加性要求。

第四章 模型仿真验证与机理检验

4.1 实验设计

为评估第三章提出的 DCI-MLTA 模型在处理宏观时序数据方面的动态稳定性和区分能力，本章节通过蒙特卡洛模拟方法进行了详细的机理检验实验。该实验旨在比较四种不同的权重确定方法在稳定性及区分度上的表现：传统熵权法；基于指数时间注意力机制的改进熵权法；结合机器学习序列建模的改进熵权法；完整的 DCI-MLTA 模型。其中，指数时间注意力改进方法采用半衰期衰减函数$\omega_t = 2^{t/(Y-1)}/\Sigma 2^{t/(Y-1)}$计算时间权重，对近期数据赋予更高权重；机器学习趋势分解改进方法采用二阶多项式回归对原始序列进行趋势挖掘，仅基于挖掘的趋势成分计算熵权；完整的 DCI-MLTA 模型的顶层参数 α 与内层参数 λ 均固定设置为 0.7，旨在平衡静态信息与动态信息、趋势成分与扰动成分的相对重要性。为了确保实验数据具有多样性和代表性，所有模拟数据均依据第三章所述的四类典型宏观经济演化模式生成：凹形增长、凸形增长、线性趋势以及周期性波动。具体来说，构建了一个三维面板数据集$f_{i,j,t}$（其中$i = 1, \ldots, 10$代表被评估实体，如国家或地区；$j = 1, \ldots, 10$代表不同经济指标；$t = 1, \ldots, 10$表示年度），其生成过程如下：

$$f_{i,j,t} = s_{i,j} \cdot g_j(t) + o_i + \varepsilon_{i,j,t}$$

其中，$s_{i,j} \sim N(1, 0.2)$表示个体-指标特定的比例因子，用以反映截面差异；$o_i \sim N(0,1)$代表个体固定效应；$\varepsilon_{i,j,t} \sim N(0, 0.5^2)$为独立同分布的随机误差项；$g_j(t)$则是第$j$个经济指标随时间变化的趋势函数，根据以下规则分配：前三个指标采用凹形增长模式（$g_j(t) = 10 - 5e^{-0.1t}$），接下来的三个指标采用凸形增长模式（$g_j(t) = t^{1.5}$），第七和第八个指标遵循线性增长规律（$g_j(t) = 2 + 0.5t$），最后两个指标展示周期性波动特征（$g_j(t) = 5\sin(2\pi t/8)$）。

实验评估包含两大部分：稳定性测试和敏感度分析。稳定性测试采用滚动窗口策略，即利用前 8 年、前 9 年及全部 10 年的数据分别计算权重向量W_8、W_9和W_{10}，并通过平均余弦相似度来衡量权重的一致性：

$$\text{avg_cos} = \frac{1}{2}[\cos(W_8, W_9) + \cos(W_9, W_{10})]$$

此处$\cos(\cdot,\cdot)$定义为 1 减去余弦距离，其值域为[0,1]，数值越高表明权重越稳定，受新增观测值

的影响越小。

敏感度分析则通过对完整样本施加三种类型的结构化扰动来进行，计算扰动前后各实体综合得分$S_i = \sum_j W_j \cdot \overline{f_{i,j,t}}$（$\overline{f}$为时间平均值）的变化，并使用斯皮尔曼等级相关系数$\rho$来量化排名变动情况。$\rho$接近 1 意味着排名相对稳定，表明模型对外部干扰不敏感；较低的ρ值则显示模型能够有效捕捉到结构变化带来的影响，显示出更高的区分度。

针对现实中的宏观经济现象，本研究设计了以下三类情景模拟：情景 A，局部持续性增长。模仿某些经济体在特定领域的后期爆发式增长（例如新兴产业的发展）。选择几个特定实体的部分指标，在最后两年的数据中乘以 1.3 倍。这有助于考察模型识别新兴机会的能力；情景 B，全局短期冲击。模拟无差别的外部事件影响（比如全球金融危机），对所有实体的所有指标在某一年份（如第六年）的数据乘以 0.75 倍。理想的模型在这种情况下应表现出较高的鲁棒性，即排名基本保持不变（$\rho \approx 1$）；情景 C，结构性趋势转变。模拟由于政策调整或技术创新引起的分化趋势。对一部分实体的关键指标实施持续增长，而对另一部分则施加持续下降的趋势。此情景主要用于测试模型应对复杂且矛盾性的结构变化的能力。在机器学习模型方面，选择了二阶多项式回归作为趋势拟合的方法，以平衡灵活性与稳健性，避免过拟合问题。

4.2 实验结果

4.2.1 稳定性检验结果

通过 200 次蒙特卡洛模拟实验达到收敛，稳定性以平均余弦相似度作为评估指标，所有方法在无显著结构突变的基准情景下均展现出较高的时间稳定性（均值 ＞0.996）。

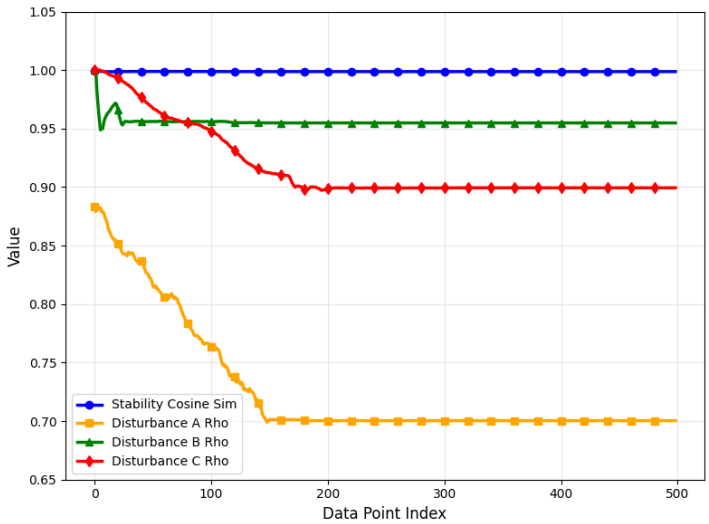

表 4-1 权重稳定性检验结果

评价方法	均值	标准差
传统熵权法(EWM)	0.9985	0.0011
EWM+指数时间注意力	0.9978	0.0018
EWM+机器学习趋势分解(Poly2)	0.9967	0.0008
DCI-MLTA 完整模型(Poly2)	0.9986	0.0009

从表 4-1 可见，DCI-MLTA 完整模型展现出略优于其他方法的稳定性表现，特别是显著优于仅整合机器学习趋势分解的 EWM 变体（t 检验，p<0.01）。这一结果验证了模型设计中"趋势-扰动解耦"机制的有效性：通过为趋势成分与扰动成分分别构建独立的评价通道，DCI-MLTA 有效隔离了单一模型拟合可能引入的波动性，从而在理论层面实现了结构性稳健。相比之下，仅引入指数时间注意力的 EWM 变体因对近期观测赋予过高权重，导致其稳定性相对较低且变异程度更大（标准差为

0.0018），这在宏观经济评价中可能导致对短期波动的过度反应。

4.2.2 区分度检验结果

如表 4-2 所示，呈现了三类结构性扰动情景下各评价方法的斯皮尔曼等级相关系数(ρ)，用以衡量评价排序对扰动的敏感程度。数值越低，表明模型对结构性变化的区分能力越强。

表 4-2 三类扰动情景下的区分度检验结果（斯皮尔曼相关系数 ρ）

评价方法	情景 A：局部持续性增长	情景 B：全局短期冲击	情景 C：结构性趋势转变
EWM+指数时间注意力	0.7682 ± 0.2944	0.9558 ± 0.1348	0.9380 ± 0.1493
EWM+机器学习趋势挖掘(Poly2)	0.7005 ± 0.3086	0.9591 ± 0.1206	0.8942 ± 0.1894
传统熵权法(EWM)	0.7615 ± 0.3052	0.9565 ± 0.1397	0.9266 ± 0.1524
DCI-MLTA 完整模型(Poly2)	0.7004 ± 0.3083	0.9548 ± 0.1401	0.8997 ± 0.1662

情景 B 全局短期冲击下，所有方法的相关系数高度一致，均值约为 0.956，表明各模型均能有效识别此类无差异性的外部冲击，保持评价排序的基本稳定。这一结果符合综合评价稳健性优先的基本原则，即评价体系应避免将整体性外部冲击误判为个体性差异，从而维持决策的连续性与一致性。

情景 A 局部持续性增长结果揭示了方法间的显著差异。DCI-MLTA 与机器学习趋势分解改进熵权法的相关系数显著低于传统熵权法及其时间注意力变体，表明这两种方法能更有效地捕捉特定实体在关键发展阶段的结构性突破。这一优势源于其对指标演化路径的动态建模能力，使权重分配能够反映指标在不同发展阶段的信息价值变化。

在情景 C 结构性趋势转变的表现中，DCI-MLTA 模型展现出最低的相关系数 0.8997，表明其对复杂分化格局的响应最为敏感。相比之下，传统熵权法及其时间注意力变体的相关系数高达 0.92 至 0.94，反映出这些方法难以解耦相反方向的趋势变化，导致评价信号的结构性模糊。值得注意的是，尽管机器学习趋势分解改进熵权法也表现出较低的相关系数 0.8942，但其变异程度最大，标准差 0.1894，表明在复杂情景下缺乏稳定性。而 DCI-MLTA 在保持高区分度的同时，标准差相对较小，0.1662，体现了其作为完整模型框架的综合优势。

第五章 基于中国省级碳排放的动态综合评价指数构建实证研究

5.1 实验设计

为严谨评估 DCI-MLTA 模型在真实复杂决策场景下的有效性，本研究构建了一个滚动决策支持与面板固定效应回归相结合的双重验证框架。该设计的核心思想是：若一个综合评价指数能有效捕捉区域发展的内在结构，则其应能为关于未来结果的决策提供前瞻性的信息支撑。这比单纯的内部一致性检验更具外部效度，也更契合管理科学研究中辅助决策的核心目标。

5.1.1 数据来源与处理

本研究所用数据为 2010–2022 年中国 30 个省级行政区（不含港澳台及西藏，因部分数据缺失）的面板数据，数据来源于《中国能源统计年鉴》《中国统计年鉴》及各省统计年鉴。数据集包含 17 项反映产业结构、人口规模、能源消费等维度的社会经济指标，构成多指标综合评价的数据源。核心的决策结果变量为“碳排放量（万吨）”，该变量不参与任何权重计算过程，仅作为检验模型决策支持效力的基准。所有指标在进行计算前均经过 Min-Max 标准化处理，以消除量纲影响。

5.1.2 滚动决策支持流程

为模拟管理者基于历史信息进行未来决策的真实情境，本研究设计了滚动决策支持流程。具体

而言，对每个决策时点t，首先进行信息集成：基于第 1 年至第 t 年的历史数据 $\mathbf{X}_{:,:,1:t}$，通过某一赋权方法（如原始 EWM、DCI-MLTA 等）计算权重向量 $\mathbf{w}^{(t)} \in \mathbb{R}^{17}$。该权重向量代表了管理者在 t 时点，基于历史信息形成的对各指标重要性的判断。随后进入决策信号生成阶段：利用第 t 时点形成的权重 $\mathbf{w}^{(t)}$，对第 $t+1$ 年的标准化指标值 $\tilde{\mathbf{x}}_{i,:,t+1}$ 进行加权，得到第 i 省份在第 $t+1$ 年的综合发展决策信号：

$$s_{i,t+1} = \sum_{j=1}^{17} w_j^{(t)} \cdot \tilde{x}_{i,j,t+1}$$

此处的决策信号 $s_{i,t+1}$ 完全基于历史信息生成，它模拟了管理者在 t 时点对 $t+1$ 年发展态势的判断，为后续的决策分析提供了纯样本外的输入。此过程共生成 4 个决策时点、120 个观测值（30 省×4 年）的决策信号样本集，用于后续的回归分析。

5.1.3 决策效力评估模型

为检验综合发展决策信号对碳排放这一关键结果变量的解释力，并控制各省份不随时间变化的固有特征（如资源禀赋、地理区位等），本研究构建如下面板固定效应模型：

$$\log(C_{i,t} + 1) = \beta_0 + \beta_1 s_{i,t} + \mu_i + \varepsilon_{i,t}$$

其中：$\log(C_{i,t} + 1)$ 为对碳排放量进行对数变换（加 1 以避免零值问题），以缓解其右偏分布特征；$s_{i,t}$ 为第 i 省第 t 年的综合发展决策信号，由前一年信息生成，代表了基于历史判断对未来结果的解释力；μ_i 为省份固定效应，用于吸收如资源禀赋、制度环境等不随时间变化的个体异质性；$\varepsilon_{i,t}$ 为随机扰动项，其标准误按省份进行聚类估计，以处理面板数据中常见的组内序列相关问题。

模型的有效性通过一个综合评估体系进行检验。核心在于考察由不同模型生成的综合发展决策信号对碳排放的解释力，这主要通过调整 R^2与系数 β_1 来体现：调整 R^2衡量了模型的整体拟合优度，而系数 β_1 及其统计显著性则直接反映了决策信号对碳排放的边际影响强度。最终，通过系统比较 DCI-MLTA 模型与各基准方法在上述指标上的表现差异，可以判断 DCI-MLTA 是否能为管理者提供更高质量、更具洞察力的决策支持，从而验证其在真实管理情境下的优越性。

5.2 实验结果分析

5.2.1 稳定性表现

首先检验模型在真实数据中的权重稳定性。如表 5.1 所示，所有方法在 11→12 年、12→13 年的权重余弦相似度均超过 0.9989，表明在无重大结构性断裂的背景下，权重体系整体稳健。

方法	cos(2010–2020, 2010–2021)	cos(2010–2021, 2010–2022)	平均
原始熵权法	0.9999	0.9999	0.9999
熵权法+时间注意力	0.9999	0.9999	0.9999
熵权法+机器学习趋势(Poly)	0.9993	0.9999	0.9996
DCI-MLTA(Poly)	0.9989	0.9994	0.9992

5.2.2 外部有效性检验

为检验 DCI-MLTA 模型在真实决策场景中的有效性，本节基于 5.1 节设计的滚动决策支持框架，对十种不同的模型配置进行了实证评估。该评估的核心问题是探讨相较于传统方法，DCI-MLTA 模型构建的综合指数评估体系是否能为关于未来碳排放的决策提供更高的信息价值和指导意义。

在实证过程中，为了考察 DCI-MLTA 框架对不同趋势捕捉能力的敏感性，选择了四种具有代表性的机器学习模型作为趋势提取器：二阶多项式回归、岭回归、随机森林与 XGBoost。这些模型分别代表了从简单参数化到复杂非参数化的不同拟合能力，有助于系统性地分析趋势建模方式对最终评价效果的影响。

表 5.2 展示了所有模型配置下，综合发展决策信号对未来一年碳排放对数值的面板固定效应回归结果。从表中可以观察到几个关键发现。首先，所有模型的综合发展决策信号均与碳排放显著正相关。无论采用何种权重方法，其回归系数均在 1%的水平上显著为正，这验证了本研究构建的指标体系与综合发展指数的合理性，即区域综合发展水平的提升确实伴随着碳排放的增加。

进一步分析显示，在多数配置下，DCI-MLTA 框架展现出显著的优越性。与基准的原始熵权法相比，DCI-MLTA 结合二阶多项式回归和 XGBoost 的模型拟合优度有明显提升。这表明，通过趋势-扰动解耦与双通道注意力机制，DCI-MLTA 能够构建出与未来结果关联更紧密的综合指数，为决策提供了更为可靠的依据。

此外，趋势建模方式的选择对模型性能至关重要。在 DCI-MLTA 框架内部，采用 XGBoost 和多项式回归进行趋势提取的模型表现最佳，而采用岭回归和随机森林的版本表现相对较弱。这一结果说明，能否有效捕捉数据中复杂的非线性趋势是决定模型能否提炼出高质量决策信号的关键。DCI-MLTA 框架的优势在于它能与强大的趋势捕捉工具协同作用，从而最大化其决策支持效能。

最后，DCI-MLTA 模型提供的决策信号具有更强的边际指导意义。从核心系数来看，表现最佳的 DCI-MLTA（Poly/XGB）模型的系数为 0.0005，高于原始熵权法及其他多数基准方法的 0.0004。这意味着由 DCI-MLTA 生成的综合指数每提升一个单位，其对碳排放变动的边际指示效应更强，能够帮助决策者更敏锐地识别发展态势对环境压力的影响。这种增强的边际指导意义不仅提升了模型的实际应用价值，也为未来的政策制定提供了更加科学的依据。

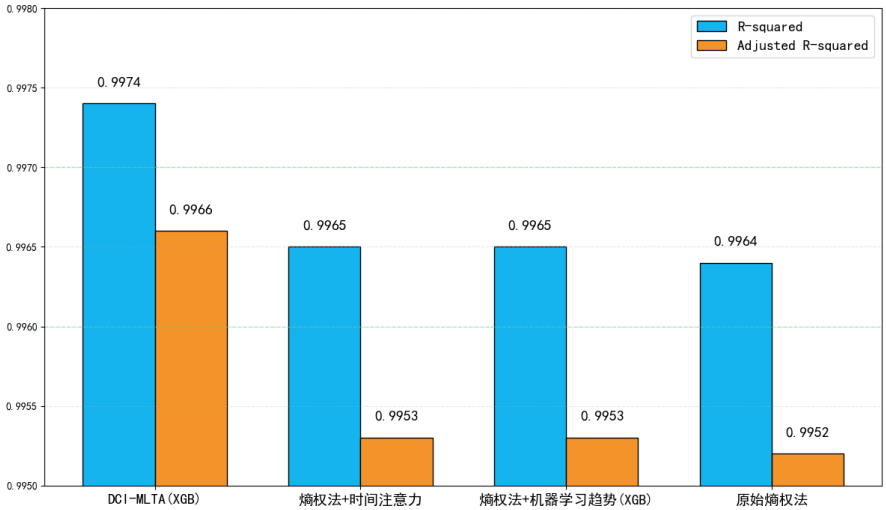

表 5.2 面板固定效应回归结果汇总

方法	R-squared	Adj. R-squared	Score Coef.	Score P-value
DCI-MLTA(XGB)	0.9974	0.9966	0.0005	0.0000
DCI-MLTA(Poly)	0.9970	0.9960	0.0005	0.0000

熵权法+时间注意力	0.9965	0.99534	0.000	0.00000
熵权法+机器学习趋势(XGB)	0.9965	0.99534	0.000	0.00000
熵权法+机器学习趋势(Poly)	0.9965	0.99534	0.000	0.00000
原始熵权法	0.9964	0.99524	0.000	0.00000
熵权法+机器学习趋势(Ridge)	0.9964	0.99524	0.000	0.00000
熵权法+机器学习趋势(RF)	0.9964	0.99514	0.000	0.00000
DCI-MLTA(RF)	0.9954	0.99383	0.000	0.00001
DCI-MLTA(Ridge)	0.9937	0.99163	0.000	0.01483

5.2.3 权重分布特征与区域发展特征分析

DCI-MLTA-XGB 模型的权重分配结果揭示了中国省级区域发展的结构性特征。土地面积的平均权重最高，达到 18.7%，表明资源禀赋在区域发展评价中仍具有基础性地位。煤油消费量和燃料油消费量的权重分别为 14.8%和 14.6%，居于前列，这与燃料油消费量呈现出的长期趋势权重最大变化值为 0.0902 相吻合，说明燃料油消费所代表的工业与运输用能具有持续的演进动力；同时，煤油消费量也表现出最明显的短期波动权重增长变化值为 0.0572，反映出航空运输等活动易受经济周期与突发事件的冲击。

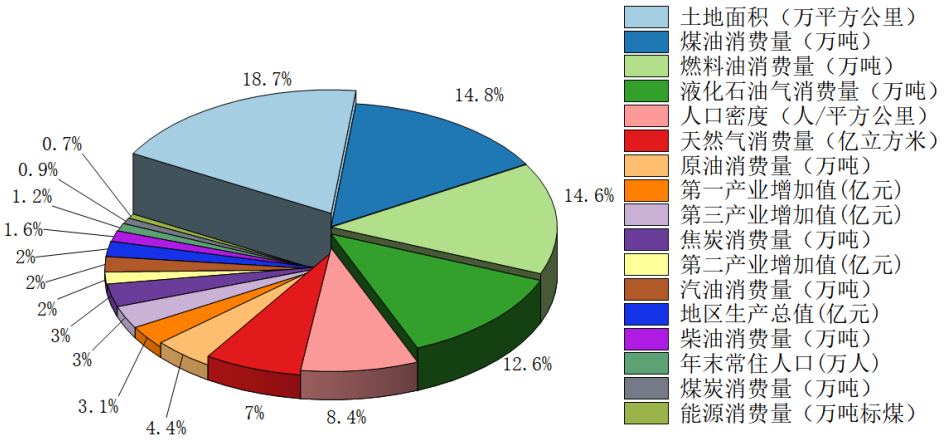

图：指标构建结果

从省份类型来看，广东、江苏、山东等经济大省的趋势权重与波动权重相对均衡，系统稳定性较强；而山西、内蒙古等资源型省份的煤炭消费量波动率权重在 8.9%至 9.3%之间，明显高于全国 6.5%的平均水平，显示出其在能源结构转型过程中面临的短期调整压力更为突出。以 2016 年供给侧改革为观察节点，改革初期确实引发了煤炭等相关指标权重的短期波动，但从中长期看，清洁能源与第三产业等相关指标的权重稳步上升，表明政策冲击经过市场与行政消化后，整体结构正在向低碳化、高附加值方向演进。

这一赋权结果不仅量化了不同指标的长短期贡献，也为区分各省份的发展模式、识别结构性风险提供了依据，有助于实现从静态评价向动态诊断与预警的政策管理功能延伸。通过 DCI-MLTA 模

型的双通道设计，决策者可以清晰区分哪些变化是应顺势引导的长期趋势，哪些是需要政策对冲的短期扰动，从而将评价功能从事后总结拓展至事中诊断与前瞻预警。

第六章 模型参数讨论

6.1 管理科学概念界定：趋势性与扰动性

综合指标评价体系在管理科学中的核心功能并非仅用于事后比较或静态排序，而是服务于资源配置、绩效诊断、风险识别与策略调整等决策活动。与工程或统计分析中追求最优拟合不同，管理决策更强调在不完全信息条件下，对系统运行状态及其未来走向作出可解释、可操作且具备情境适应性的判断。因此，评价模型是否能够区分不同时间尺度上的信息特征，直接决定其管理价值。

近年来，随着宏观经济波动加剧、技术迭代加速以及政策环境不确定性上升，组织研究、战略管理与危机管理领域的文献逐步形成共识：管理决策所面对的并非静态均衡世界，而是一个同时包含长期演化规律与短期冲击噪声的动态系统。管理动态性主要来源于两类不同但相互交织的因素，一类是长期相对稳定的演化力量，另一类是短期不规则的外生或内生冲击。OECD 将证据导向政策制定界定为在政策设计、实施与必要时调整过程中，系统使用统计数据、研究证据与政策评估结果的过程，并强调政府需要具备相应能力以实现敏捷且有响应力的治理【1】。危机时期的政策评估研究同样指出，面对如疫情等系统性冲击，政府必须在短期内使用高频数据与快速证据工具开展政策判断，并将干预措施按短、中、长期进行划分，以避免把短期波动误判为长期结构趋势【2】。企业管理相关研究也证实，不同时间尺度上的变化信号对管理判断具有本质不同的含义，若不加区分地混合处理，往往会导致误判与过度反应【3】【4】。

基于上述理论背景，本研究将动态管理决策情境抽象为趋势性与扰动性两个核心维度。趋势性指评价对象在较长时间尺度上呈现的方向性、持续性与相对可预测性特征。在宏观治理中，它对应于经济发展中的结构性演化，如产业结构升级、技术进步带来的潜在增长变化、制度能力提升、公共服务供给质量改善等。趋势性信息通常体现在中长期序列中，具有较强的路径依赖与累积性，适合支持战略规划、制度建设与中长期资源配置。扰动性指评价对象在较短时间尺度上受到冲击后出现的异常波动、局部跳变与随机性增强。在宏观治理中，扰动性往往来自外部冲击与制度环境变化，如全球需求收缩、地缘冲突、公共卫生事件、能源价格冲击、政策不确定性上升等，也可能来自内部结构调整的短期摩擦。扰动性环境下政策判断需要更依赖高频信息与快速评估机制，否则容易发生反应滞后或误判信号。

在管理实践中，趋势性与扰动性并非相互排斥，而是共同构成评价环境的基本特征。基于此，本研究以趋势性—扰动性构建管理决策情境的二维框架，如图 8 所示，用于刻画不同评价对象所处的动态环境，并为后续模型参数的设定提供概念依据。

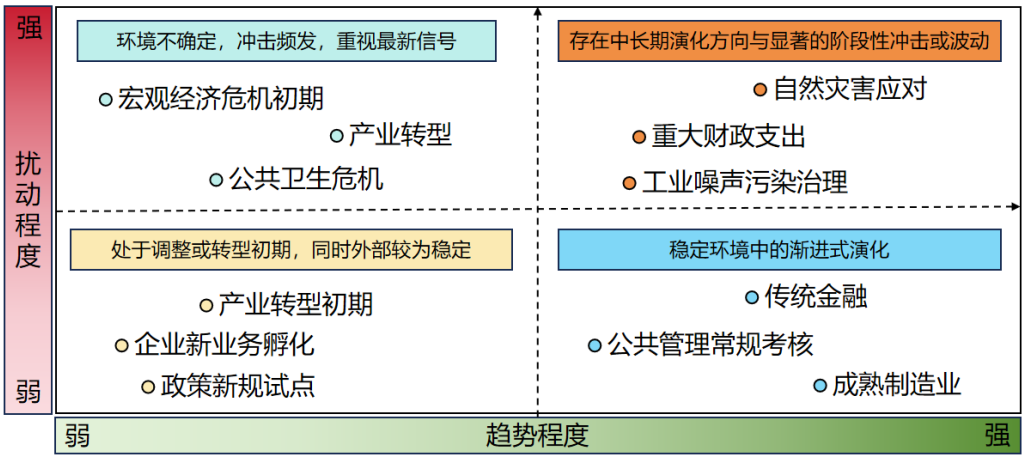

图 8 趋势-扰动管理框架

（一）弱趋势—强扰动情境

该情境评价对象缺乏清晰、稳定的长期演化路径，结构化信息占比有限，而外部冲击、随机波动或突发事件对系统运行状态产生主导性影响。在此类环境中，指标序列往往呈现出高频震荡、局部跳变与结构不稳定特征，历史趋势对未来状态的解释力显著下降。如宏观经济危机初期、金融市场剧烈波动阶段、资源价格冲击下的能源密集型产业，或制度尚未定型的新兴市场经济体。对于管理者而言，评价体系若过度强调长期趋势，容易掩盖关键风险节点；相反，提高对短期扰动的敏感度，有助于及时触发预警与干预机制【5】。

（二）强趋势—弱扰动情境

强趋势—弱扰动情境是指系统运行具有清晰、稳定且可预测的长期演化轨迹，短期随机波动幅度有限，外部冲击对整体结构的扰动较小。在该情境下，指标序列表现为平稳演进或近似线性增长，跨期比较具有较强可比性。这一类型广泛存在于成熟制造业、公用事业、传统金融体系及公共部门常规治理领域，如年度绩效考核、预算执行评估与基础公共服务供给效率评价等。管理决策更侧重于目标达成度、过程控制与资源使用效率，而非频繁调整战略方向【6】【7】。

（三）弱趋势—弱扰动情境

弱趋势—弱扰动情境通常出现在系统处于结构调整或转型初期阶段，既有发展路径正在弱化，但新的稳定趋势尚未完全形成，同时外部冲击相对有限，整体波动水平处于可控区间[8]。此时，指标序列既不呈现显著的长期方向性，也未出现剧烈的短期异常。该情境常见于产业转型期的企业战略重构、新业务孵化阶段，或制度改革早期的政策试点区域。管理决策面临的主要挑战在于信息不充分与路径不确定性，而非风险冲击本身。在此背景下，评价体系的功能更多体现在辅助探索与学习，通过持续观察不同指标的相对变化，帮助管理者识别潜在演化方向，而非给出明确的最优解。

（四）强趋势—强扰动情境

强趋势—强扰动情境指系统同时存在清晰的中长期演化方向与显著的阶段性冲击或波动。指标序列在整体上呈现结构性演进，但局部时期可能因政策调整、外部冲击或制度摩擦而出现明显偏离。该情境在公共政策实施、重大财政支出项目、环境治理与社会发展规划评估中尤为常见。例如，政策目标具有明确的中长期导向，但执行过程中不可避免地受到经济周期、社会反馈或突发事件的影响。管理者在此类环境中需要在保持战略定力与及时纠偏之间取得平衡，既要识别趋势偏离是否具有结构性意义，又要避免因短期波动引发过度反应【9】。

6.2 参数敏感性分析

根据趋势-扰动管理框架两个关键参数管理学场景下概念为：

参数 α 为静态信息与动态信息的权重分配参数，直接决定了评价最终结果时，基于当期数据的截面比较与纳入时间过程的演化分析两者的相对重要性。α 值接近 1，意味着评价主要依据各对象在当前时点的指标表现进行横向比较。这对应管理上关注即时绩效、存量资源分配等场景，评价目标在于对现状进行精准的快照式刻画与排序。α 值接近 0，意味着评价主要依据各对象指标在时间序列中呈现的演化模式。这对应管理上关注长期潜力、发展趋势或战略韧性的场景，评价目标在于识别并奖励持续改善或具备增长动能的对象。

参数 λ 为动态演化信息中趋势性信号与扰动性信号的调节参数，在动态信息内部决定了将观测到的变化更多地关注长期结构性趋势，还是关注短期随机性扰动。λ 值接近 1，意味着在构建动态权重时，趋势信息的贡献占主导。这适用于发展战略评估、转型升级进程监测或基础能力建设评价等场景。此时，模型倾向于基于对象间的长期发展趋势差异及其关键转折点来分配权重，旨在强化对根本性、方向性潜能的识别。λ 值接近 0，意味着在构建动态权重时，扰动信息的贡献占主导。这适用于风险预警、压力测试、危机应对效果评估或政策干预的短期反馈等场景。此时，模型倾向于基于对象对外部冲击或内部异常波动的暴露程度与异质性反应来分配权重。

为验证 DCI-MLTA 模型在不同演化环境下的参数响应机理，本节采用蒙特卡洛模拟方法构建具有已知生成过程的合成数据。一方面，合成数据能够屏蔽现实系统中难以控制的测量误差与结构性共变，从而将解释力差异更清晰地归因于参数变化；另一方面，通过重复实验使参数结论更具稳健性

6.2.1 静态－动态平衡参数 α 的敏感性

在不同数据结构下的适用性，本研究设计了涵盖四类典型宏观演化模式的仿真实验：线性主导模式、周期主导模式、随机主导模式与混合模式。每种模式下固定 λ，令 α 从 0 到 1 以 0.1 为步长变化，通过 200 次蒙特卡洛模拟计算对应的调整后 R^2如表 6-1 所示。

表 6-1 四类模拟宏观演变数据特征定义

数据模式	数学特征描述	对应宏观管理情境
线性主导型	$f(t) = kt + b + \varepsilon$ 一阶导数近似常数，趋势项占主导	成熟期产业/稳定增长经济体 如公用事业、基础设施建设，具有强惯性与高可预测性。
周期主导型	$f(t) = A\sin(\omega t + \phi) + \varepsilon$ 存在显著的波峰与波谷，非线性特征强	受周期影响显著的行业 如航运业、大宗商品市场，受库存周期或朱格拉周期支配。
随机主导型	$f(t) = f(t-1) + \varepsilon$ 随机游走过程，趋势项微弱	高不确定性/初创环境 如风险投资市场、颠覆性技术早期，缺乏历史规律，随机性强。
混合复杂型	上述三种模式的线性组合	现实宏观经济系统 大多数实际评价对象，既包含长期增长趋势，又受周期和随机冲击影响。

实验结果如下

数据场景特征	最优 α 范围	峰值 Adj. R2
线性主导型	高区间 [0.8,1.0]	0.968
周期主导型	低区间 [0.0,0.3]	0.966
混合复杂型	中高区间 [0.3,0.8]	0.975
随机主导型	两极分化 ≈ 0.0 或 1.0	0.961

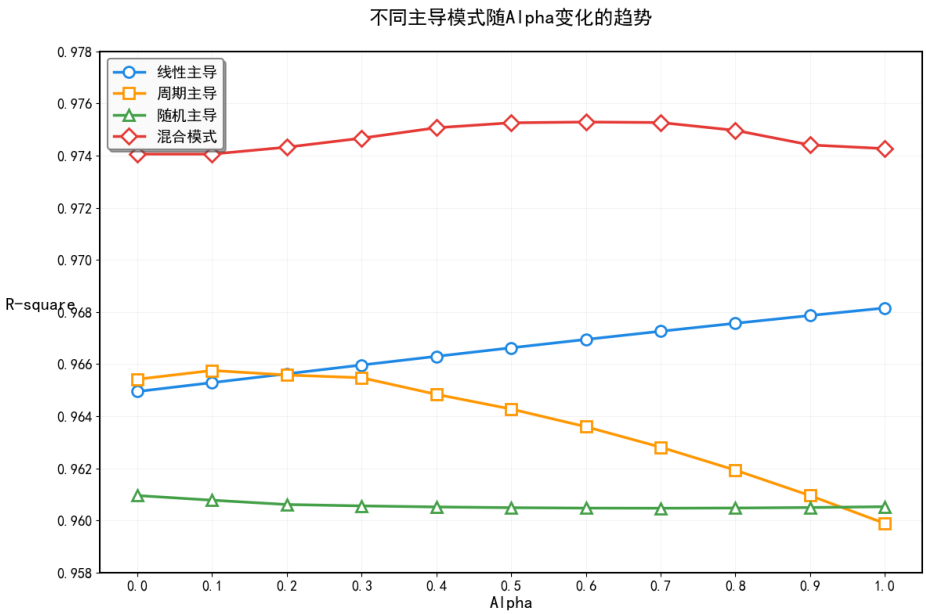

（1）线性主导型随着 α 增大调整 R^2 增大，说明当系统主要由单调稳定趋势决定时，传统截面区分度已足以支撑评价，额外引入时序调节的边际收益有限，甚至可能引入不必要的模型噪声。

（2）周期主导型随着 α 增大调整 R^2 降低，适度引入动态视角 α<0.3 能够有效捕捉周期转折点蕴含的关键信息。然而，当 α 过小时，完全依赖动态权重会过度放大短期波动，忽视截面数据的基

准区分度。因此，对于周期性指标，推荐采用 α∈[0.1,0.3]的均衡配置，在保持截面可比性的同时增强对周期相位变化的敏感性。

（3）混合复杂型 α∈[0.5,0.7]内表现最优，验证了静态与动态信息具有互补性：静态权重刻画当期差异，动态权重提供趋势—扰动解耦后的跨期稳定性；两者线性合成能够在大多数现实系统中获得更稳健的解释力。

（4）随机主导型 α 在整个[0,1]范围内变化时，调整 R^2的波动幅度极小，α ∈[0,0.1]性能略优。这一现象揭示了综合评价方法的一个基本局限，当评价对象的演化过程本质上是高度随机的，这反映了熵权法及其扩展在处理无结构数据时的方法论边界，而非模型本身的缺陷。在实际管理应用中，当面对高度不确定性环境时，参数选择可更侧重于管理目标与决策偏好，而非追依据统计方法判断。

6.2.2 趋势-扰动权衡参数 λ 的敏感性分析

参数 λ ∈[0,1]作为模型的内层调节参数，控制着动态权重中趋势性信息与扰动性信息的相对重要性。为检验 λ 在不同扰动环境下的表现，本研究在线性主导基线上施加了 0%、10%、20%三类结构性扰动，固定 α =0.5 以突出动态成分的作用。

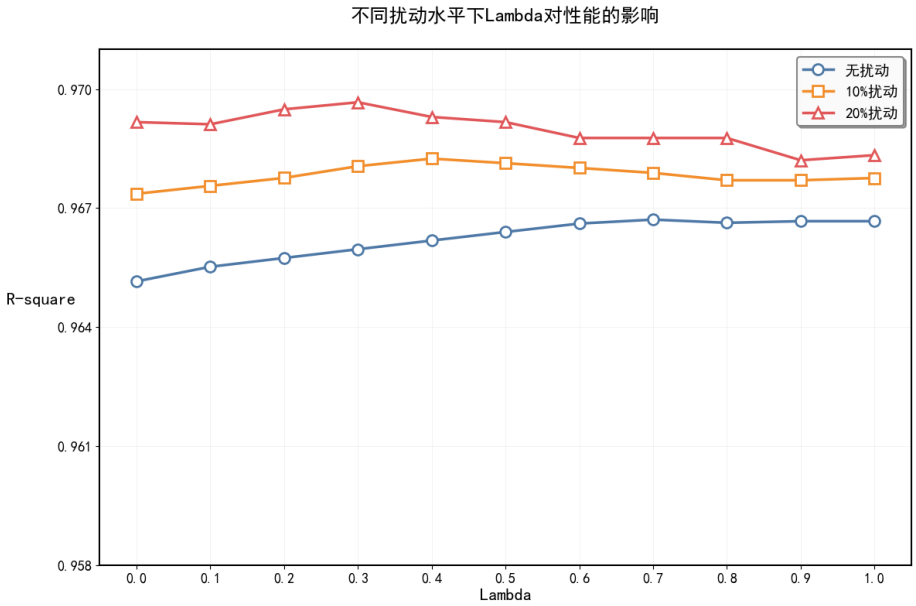

表 6-3 不同扰动强度下参数λ实验结果

扰动强度情境	最优 λ 范围	峰值 Adj. R2
无扰动 (Baseline)	高区间 [0.7,1.0]	0.967
中度扰动 (10% Noise)	中低区间 [03,0.6]	0.968
高强度扰动 (20% Noise)	低区间 [0.2,0.4]	0.969

（1）无扰动环境下的 λ 参数响应

在无扰动情境下，模型性能随 λ 增大而轻微下降。这一现象符合理论预期：当系统运行平稳、未受外部冲击时，残差项主要包含随机噪声而非结构性信息。此时，过度关注扰动通道（λ→0）会降低权重估计效率，而聚焦趋势通道（λ→1）则能更好捕捉内在演化规律。

（2）适度扰动下的参数优化

当系统受到 10%的外部冲击时，最优 λ 向中低区间移动，表明残差开始携带管理上有价值的信号例如冲击暴露程度、短期韧性差异，模型需降低对趋势项的单边依赖，转而提高对异常波动的捕捉能力。

（3）强扰动环境下的稳健性配置

在 20%的强扰动情境下，模型在 λ∈[0.2,0.4]区间表现最优，这一结果具有重要管理启示：当系统面临重大外部冲击时，既不能完全依赖历史趋势，也不能过度响应短期波动。对于危机管理、产

业重构等强不确定性场景，应重视不确定因素的影响。

6.3 趋势-扰动框架下参数使用建议

基于前文对趋势性与扰动性管理框架的构建以及参数敏感性实验的结果，本研究提出一个整合的参数配置决策矩阵。该矩阵将四个典型管理情境与 DCI-MLTA 模型的参数设置直接关联，为决策者提供明确的操作指南。如表 6-4 所示，参数配置应根据评价对象所处的动态环境特征进行差异化设定。

表 6-4 趋势-扰动框架下的参数配置决策矩阵

管理情境	α 范围	λ 范围	适用场景举例
弱趋势-强扰动	0.0-0.3	0.2-0.4	突发公共卫生事件应对、金融危机初期、自然灾害后重建评估
强趋势-弱扰动	0.8-1.0	0.7-1.0	成熟行业绩效评价、基础设施投资回报评估、公共服务质量常规监测
弱趋势-弱扰动	0.4-0.6	0.4-0.6	产业转型期企业评估、新兴技术发展监测、制度改革试点效果评价
强趋势-强扰动	0.5-0.7	0.3-0.6	长期环境治理政策评估、国家发展战略阶段性评估、财政支出中期绩效评价

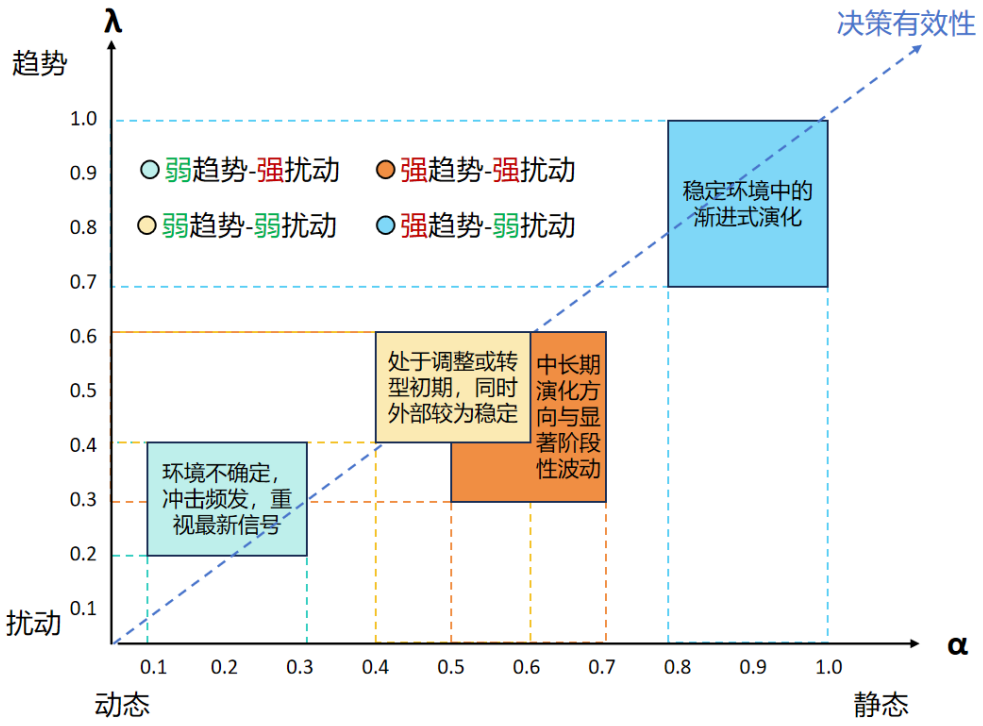

【弱弱和强强重叠也有管理道理，这里篇幅有限就不展开了】

基于趋势-扰动二维框架，DCI-MLTA 模型参数应根据管理情境差异化配置：弱趋势-强扰动情境,如危机响应,推荐 α ∈[0.0,0.3]与 λ ∈[0.2,0.4]，强调动态信息与扰动信号捕捉；强趋势-弱扰动情境,如成熟行业评价,采用 α ∈[0.8,1.0]与 λ ∈[0.7,1.0]，侧重静态截面比较与长期趋势识别；弱趋势-弱扰动情境,如转型初期,适用 α ∈[0.4,0.6]与 λ ∈[0.4,0.6]的均衡配置，保持观察中立性；强趋势-强扰动情境,如战略规划,选择 α ∈[0.5,0.7]与 λ ∈[0.3,0.6]，平衡长期方向与短期调整。参数配置操作可遵循四步流程：首先通过历史数据与专家判断诊断情境类型；其次选取对应参数初始值；然后进行历史回

溯验证，检验模型对已知事件的识别能力；最后根据管理反馈与环境变化动态校准参数。这一方法将参数选择从技术问题转化为管理理念与情境特征的映射过程，使评价体系真正成为连接数据特征与决策需求的桥梁，为复杂动态环境提供更加精准、可解释的决策支持。通过参数的情境化配置，DCI-MLTA 模型实现了从一刀切评价工具到灵活决策平台的转变。

结论与展望

7.1 研究结论

本文围绕传统客观赋权方法难以内生处理时序信息、易将短期扰动误判为有效差异或忽视长期趋势的方法论缺口，提出并系统构建了基于机器学习与时间注意力的动态综合指数模型（DCI-MLTA）。模型的核心思想是将指标序列视为“结构性趋势 + 非结构性扰动”的复合体，通过机器学习对趋势分量进行拟合分解，并以双通道注意力机制分别刻画趋势变化强度与扰动冲击强度，在此基础上形成动态权重并与传统熵权法静态权重进行可调节融合。该框架使综合评价从单一截面加权扩展为“截面—时间”二维加权，并将管理者的评价偏好显式映射为两个可解释参数：静态－动态权衡 α 与 趋势－扰动权衡 λ 。

第三章仿真与机理检验的结果表明，DCI-MLTA 在动态环境下呈现出该稳则稳、该敏则敏的性能特征。第四章基于蒙特卡洛面板数据的实验显示，在无显著结构突变的基准情景中，各方法整体稳定，但 DCI-MLTA 的滚动窗口权重一致性表现最优或同等最优；在结构性变化情景，如局部持续增长中，DCI-MLTA 相较传统熵权法及其简单时间注意力变体能够更敏感地反映真实分化，同时又避免了仅趋势拟合方案在复杂情景下稳定性不足的问题。这说明趋势—扰动解耦 + 注意力匹配的结构设计，能够在稳健过滤整体性冲击的同时提升对结构性机会与风险信号的识别能力。

在真实宏观决策场景的外部有效性检验中，DCI-MLTA 同样体现出更强的决策支持能力。第五章以 2010－2022 年中国省级数据构建滚动决策支持流程，并通过固定效应回归检验综合指数对未来一年碳排放的解释力。结果显示，多数组合下 DCI-MLTA 生成的决策信号具有更高的拟合优度与边际解释强度，且当趋势提取器具备较强非线性捕捉能力如 XGBoost、二阶多项式时表现最优，表明该框架能够与机器学习趋势建模形成互补协同，从而提炼出更贴近“未来结果变量”的综合评价信号。

进一步地，第六章的敏感性分析与管理情境映射表明，α 与 λ 并非纯技术调参，而是管理偏好的形式化表达：在周期主导型系统中，α 的最优值位于低区间[0.1,0.3]，而在稳定的线性系统中则位于高区间[0.8,1.0]，反映了不同演化特征下对时间维度的差异化重视程度；λ 的最优配置随扰动强度增加而系统性下移，从无扰动环境的[0.7,1.0]降至高强度扰动下的[0.2,0.4]，体现了评价焦点从长期趋势识别向短期风险响应的自然迁移。该结论与证据导向治理强调的可解释、可调整的评估能力在逻辑上是一致的：评价模型不仅要给出排序，更应为政策迭代与管理校准提供可操作的调节维度。

综合来看，本研究的主要贡献可概括为三点：其一，在方法论层面提出趋势—扰动解耦 + 时间注意力匹配的动态综合评价范式，缓解了传统熵权法等基于离散变异度的赋权机制在时序场景下的机理错配；其二，在技术实现层面构建双层参数的可调节框架，使评价体系在静态与动态、趋势与扰动之间形成整体调节框架；其三，在应用层面通过仿真与省级碳排放实证形成闭环验证，展示了模型在稳健性—敏感性双目标下的综合优势。

7.2 未来研究展望

尽管本文已从理论推导、机理仿真与实证检验三个层面验证了 DCI-MLTA 的有效性，但仍存在若干局限需要在后续研究中进一步完善。第一，机器学习模型的选择会影响趋势—扰动分解质量，尽管本文已比较了多种模型，但对何种数据结构适配何种趋势模型的系统性选择规则仍有待深化。第二，参数 α 与 λ 的推荐区间目前主要依据仿真与实证经验总结，尚未形成统一的、可自动化的参数先验诊断—推荐机制。第三，本文主要以碳排放作为外部结果变量检验决策支持能力，未来可引

入更多结果变量与多目标治理约束，以检验模型在更复杂的政策目标体系下的稳定性与解释一致性。

未来研究可沿着模型深化、制度化应用和可复数评估三条路径推进。首先，在趋势—扰动分解层面引入更强的结构约束与可解释机制，例如结合状态空间分解、结构突变检测或多尺度分解方法，使模型对趋势拐点与阶段性结构变化的刻画更加精细，并将“拐点”与“异常冲击”进一步区分为不同类型事件，从而提升模型在复杂宏观系统中的诊断能力。其次，可以将参数推荐从经验规则推进为可复现的数据驱动诊断，通过构造扰动强度指标=和趋势结构指标，建立 α 和 λ 的先验区间映射，并通过滚动验证进行在线校准，使模型具备更强的自适应治理配置能力。这与全局敏感性分析强调的通过系统性不确定性传播提高模型可辩护性与稳健性的方法论方向一致。最后，在应用扩展方面，可以将 DCI-MLTA 推广至多类宏观治理与组织管理场景，如区域高质量发展评价、产业链韧性与风险预警、公共支出绩效与政策评估周期监测等。特别是在强趋势—强扰动的治理情境中，评价体系需要同时服务于战略定力与动态纠偏，DCI-MLTA 的双通道结构与双参数框架具有天然适配性。此外，还可以进一步将权重的动态变化解释为政策诊断信号，识别哪些指标的权重上升源于长期趋势强化，哪些源于短期冲击加剧，从而为政策工具组合与资源配置提供更明确的可操作依据。这样不仅提升了模型的应用广度和深度，还增强了其在实际管理决策中的实用性和灵活性。

7.3 项目实施过程中创新思维和创新实践方面收获

团队突破传统静态指数局限，创新引入机器学习动态权重与混合建模框架。实践中，成员将算法理论与碳排放场景深度融合，攻克了模型可解释性难题。通过跨学科协作，大家不仅掌握了前沿技术，更培养了从数据洞察到解决复杂现实问题的创新思维，实现了理论与实践的双重跃升。

参考文献

[1] OECD. (2008). Handbook on Constructing Composite Indicators: Methodology and User Guide. OECD Publishing.

[2] Mazziotta, M., & Pareto, A. (2019). Synthesis of indicators: The non-aggregative approach. Social Indicators Research, 143(1), 381–396.

[3] Kuc-Czarnecka, M., Lo Piano, S., & Saltelli, A. (2020). Quantitative storytelling in the making of a composite indicator. Ecological Economics, 168, 106483.

[4] Cavicchia, C., & Vichi, M. (2021). Statistical model-based composite indicators for tracking coherent policy conclusions. Social Indicators Research, 156(2), 449-479.

[5] Mazziotta, M., Pareto, A. Principal component analysis for constructing socio-economic composite indicators: theoretical and empirical considerations. SN Soc Sci 4, 114 (2024). https://doi.org/10.1007/s43545-024-00920-x

[6] Greco, S., Ishizaka, A., Tasiou, M., & Torrisi, G. (2022). The use of composite indicators to evaluate the performance of Brazilian hydropower plants. European Journal of Operational Research, 299(1), 352–364.

[7] Zhang, L. P., & Zhou, P. (2024). Reassessing energy security risk incorporating external shock: a variance-based composite indicator approach. Applied energy, 358, 122665.

[8] D’Amico, S., & Vitale, C. (2023). A functional approach for constructing dynamic composite indicators. Statistical Methods & Applications, 32, 19–42.

[9] Borgonovo, E., et al. (2025). Sensitivity-based weighting method for composite indicators. Annals of Operations Research.

[10] Kelemen, A., SzabÃ³, Z. K., BozÃ³ki, S., SzÃ¡doczki, Z., & Hartvig, Ã□. D. (2024). A sensitivity analysis of composite indicators: Min/max thresholds. Environmental and Sustainability Indicators, 23, 100453.

[11] 邱东. (2018). 经济测度逻辑挖掘：困难与原则. 北京：科学出版社.

[12] 王筱明, 陈柏成, 周景红. (2020). 基于时序多指标动态评价的山东省城市土地利用效益比较研究. 湖南师范大学自然科学学报, 43(04), 1-8.
[13] 何赟, 等. (2025). 基于时间序列分析的中欧班列高质量发展动态评价体系构建. 交通运输系统工程与信息, 25(2), 45-56.
[14] 谢艾玉, 等. (2025). 基于变异系数动态赋权与混合隶属度函数的湖泊水质时空评价模型. 环境科学学报, 45(3), 1128-1139.
[15] 邱东, 刘颖, 平卫英. (2025). 从方法提升到方法论——注重多指标综合评价的机理进路. 统计研究, 42(04), 3-14.

五、项目实施过程中存在的问题和建议：

项目存在时间紧、经费少等困难。建议加强团队沟通协作，优化任务分工，提高执行效率，确保项目高质量完成。

六、诚信承诺：

我承诺在项目实施过程中遵守学校有关规定，恪守学术规范。本人在项目成果中除特别注明和引用外，均为本人观点，不存在剽窃、抄袭他人学术成果，伪造、篡改实验数据的情况。如有违规行为，我愿承担一切责任，接受学校的处理。

签字：

2026 年 3 月 31 日

指导教师意见	本项目选题紧扣国家“双碳”战略与大数据技术发展的前沿热点，具有显著的理论深度与广泛的实践应用价值。项目团队敏锐地捕捉到传统综合指数构建方法在处理高维、非线性及动态时序数据时的局限性，创造性地提出将机器学习技术与传统统计学方法相融合的解决思路，选题视角新颖，切中痛点。 在研究内容与设计上，项目逻辑严密，体系完整。从多源异构数据的预处理到动态权重分配，再到混合建模框架的搭建及碳排放领域的案例验证，各个环节环环相扣，体现了较强的系统性。特别是项目提出的“机器学习驱动权重分配”与“动态自适应更新机制”，有效解决了传统方法权重固化、时效性差的问题，具有明显的创新性。同时，团队在追求模型高性能的同时，注重可解释性研究，增强了成果在决策支持中的可信度，这一点难能可贵。

	在团队表现方面，该项目是一支典型的跨学科协作团队。成员来自大数据管理、人工智能及电子商务等不同专业，充分发挥了各自在数据处理、算法建模及场景应用方面的优势。团队分工明确，协作默契，展现了扎实的专业基础、良好的科研素养及优秀的沟通能力。 综上所述，本项目研究目标明确，技术路线科学，创新特色鲜明，成果具有较高的学术价值和应用潜力。项目执行情况良好，达到了预期研究目标，同意通过验收（或建议予以优秀评价）。 指导教师签名： 2026 年 3 月 31 日